Avaliação sobre Capacidade de Transferência Translíngue em Inferência de Modelos de Linguagem ModernBERT voltada para QA Extrativo de Longo Contexto

Victor Hugo Santos Bitencourt
Departamento de Ciências Exatas e da Terra, Campus I
Universidade do Estado da Bahia (UNEB)
Salvador, Bahia, Brasil.
abjurandam@gmail.com

1 Introdução

No âmbito da Inteligência Artificial, os Grandes Modelos de Linguagem (LLMs) dominam o centro da discussão. No entanto, na pesquisa científica atual, outros tipos de modelos exibem avanços contínuos; em particular, modelos BERT *(Bidirectional encoder representations from transformers)* estão sempre no centro da discussão do campo de NLP (Processamento de Linguagem Natural), sendo utilizados para tarefas de classificação de texto, como análise de sentimento e reconhecimento de entidades nomeadas. Uma dessas tarefas consiste no *Question Answering* Extrativo, que se difere dos mecanismos de busca modernos (ex: RAG) por buscar informações diretamente no texto, retornando uma passagem, a partir de um *prompt,* sem recorrer a contexto externo [2]. Diversos trabalhos mostram numerosas aplicações de tarefas desempenhadas por modelos BERT; um trabalho mostra o QA Extrativo sendo utilizado para inferência de locais de desastres naturais em texto [3].

Tais modelos são elaborados sendo submetidos a um pré-treinamento em um conjunto geralmente massivo de dados, seguido de um processo de *fine-tuning* em um *dataset* para o desempenho de tarefas específicas. É importante destacar que, compreensivelmente, os modelos de fronteira, assim como a pesquisa em NLP como um todo, é preponderantemente debruçada tendo a língua inglesa como padrão universal. Nesse sentido, cabe o questionamento a respeito dos impactos dos idiomas dos dados de treinamento e *fine-tuning* no desempenho dos modelos em idiomas diversos, além do inglês. Afinal, há um vasto volume de modelos disponíveis publicamente, sejam em inglês, multilíngues, e nativos de outros idiomas, e os impactos dos idiomas utilizados nos treinamentos não é tão autoevidente.

Diante desse cenário, este trabalho visa investigar como esse efeito do idioma, sendo o modelo submetido a diferentes tamanhos de textos.

2 Objetivos

Investigar experimentalmente a influência do alinhamento linguístico e do tamanho dos textos de entrada no desempenho de modelos baseados em arquiteturas BERT para tarefas de *Question Answering* (QA) extrativo em português, por meio da implementação de um ambiente experimental e da avaliação comparativa de diferentes modelos e configurações de inferência.

2.1 Objetivos Específicos

- Implementar um ambiente experimental para execução e avaliação de modelos BERT em tarefas de QA extrativo, contemplando o processamento dos conjuntos de dados, a preparação dos modelos e a execução das inferências.
- Selecionar e configurar modelos pré-treinados monolíngues e multilíngues, baseados na arquitetura *ModernBERT.*
- Implementar experimentos controlados que permitam variar o tamanho de texto de entrada e comparar o desempenho dos modelos em diferentes configurações de idioma, mantendo condições de avaliação consistentes.
- Avaliar quantitativamente os resultados obtidos, utilizando métricas consolidadas para QA extrativo, especialmente *Exact Match* (EM) e *token-level* F1, considerando as configurações experimentais.
- Analisar os resultados experimentais a fim de identificar os impactos do alinhamento linguístico e do tamanho do texto de entrada na qualidade das respostas extraídas, confrontando os resultados obtidos com as lacunas e evidências identificadas na literatura existente.

3 Justificativas e Contribuições

Os avanços na Inteligência Artificial caminham continuamente; no entanto, os avanços na pesquisa com LLMs estão sempre em maior evidência se comparado com outros tipos de arquiteturas, dominando o discurso e a atenção do público em geral. Isso não quer dizer que as demais arquiteturas pararam de evoluir; pelo contrário, modelos como Laya e Jev, do tipo encoder, entraram em evidência em 2026, mostrando que estão longe de serem obsoletos e até desejáveis quando as LLMs não são suficientes ou custosas demais. No entanto, isso mostra o quanto essas demais tecnologias merecem atenção especial.

Atualmente, no âmbito da pesquisa científica, discute-se de forma muito enfática o problema do alto custo computacional e impactos ecológicos do treinamento e execução de LLMs, e traz-se ocasionalmente discursos sobre a necessidade de pausar ou frear a pesquisa em Inteligência Artificial, dentre outros motivos, por esse. A "IA Verde" é posta em diversos trabalhos como uma alternativa a esse problema, ao sugerir o uso de modelos, técnicas e ferramentas que possibilitem a substituição de modelos mais custosos para os computadores e o meio ambiente por modelos menores que possam realizar as mesmas tarefas. LLMs estão sendo utilizadas em larga escala para tarefas que modelos menores e mais especializados, como os modelos BERT, conseguem desempenhar com igual ou

superior qualidade de resultados, tal como classificação textual em categorias e extração de entidades nomeadas.

Decerto, os benefícios do uso de modelos encoder como BERT não vêm de graça, exigindo em geral seleção de modelos pré-treinados (afinal, o pré-treinamento é excessivamente custoso), seleção e limpeza de datasets, codificação dos parâmetros e pipelines de treinamento em base de dados ampla, limpa e selecionada para o propósito a ser utilizada, e o fine-tuning. Evidentemente, para extrair o melhor desses modelos, a personalização é fundamental. Por isso, é de indispensável importância o estudo dos avanços nesse cenário de IA no que diz respeito a modelos menos populares do que LLMs, que surgem em meio aos avanços no campo de estudo, como recentemente o ModernBERT.

O ModernBERT, em particular, merece uma atenção especial. Variantes pré-treinadas em português, como NorBERTo e BERTomelo, foram recentemente lançadas e contam com poucos fine-tunes publicados publicamente no HuggingFace, maior portal público de modelos para upload e download. Além disso, até modelos multilíngues baseados na arquitetura ModernBERT não são numerosos, sendo o primeiro ModernBERT multilíngue para QA Extrativo desenvolvido pelo próprio autor. Vistos esses avanços constantes e o surgimento de modelos mais ambiciosos baseados em ModernBERT, como o Laya, o estudo das capacidades de modelos novos, como o ModernBERT e sua janela de contexto estendida de 8192, para potencializar a pesquisa de modelos textuais de IA para além de LLMs é uma grande oportunidade.

4 Metodologia

Para alcançar os objetivos propostos e investigar o impacto do alinhamento linguístico e do tamanho do texto de entrada em tarefas de *Question Answering* (QA) extrativo, este trabalho classifica-se, quanto aos objetivos e procedimentos, como uma pesquisa exploratória e descritiva de natureza aplicada, fundamentada em métodos bibliográficos e experimentais [1]. A abordagem experimental permite a manipulação controlada de variáveis em ambiente computacional para a mensuração objetiva de desempenho.

O desenvolvimento do estudo divide-se nas seguintes etapas metodológicas:

1. **Levantamento Bibliográfico:** Condução de uma revisão da literatura para mapear o estado da arte em modelos *encoder-only*, transferência translingue, arquiteturas ModernBERT e o impacto de janelas de contexto estendidas em tarefas de QA extrativo.

2. **Preparação e Pré-processamento dos Dados:** Obtenção e estruturação dos conjuntos de dados de QA extrativo em língua portuguesa, compreendendo a limpeza textual, a tokenização adequada e a validação do alinhamento de intervalos de resposta para assegurar a consistência dos dados de treinamento e teste.

3. **Configuração do Ambiente Experimental:** Estabelecimento da infraestrutura computacional e da *stack* tecnológica utilizando a linguagem Python, a biblioteca Hugging Face *transformers* para o carregamento e adaptação dos modelos baseados em ModernBERT, e a biblioteca *evaluate* para a apuração padronizada das métricas de desempenho.

4. **Execução dos Experimentos de Adaptação e Inferência:** Realização do treinamento dos modelos sob diferentes configurações de alinhamento linguístico, contemplando modelos monolíngues e multilíngues, de curta e longa janela de contexto,

e variações no comprimento do texto de entrada para simular cenários de longo contexto.

5. **Avaliação Quantitativa e Análise Comparativa:** Apuração dos resultados por meio de métricas consolidadas na literatura de QA extrativo, especificamente *Exact Match* (EM) e *token-level* F1, seguida de análise comparativa para confrontar o desempenho dos modelos frente às hipóteses formuladas.

Para concretizar os experimentos, a execução metodológica fundamenta-se em uma pilha tecnológica e em técnicas específicas de Processamento de Linguagem Natural (PLN). A escolha da linguagem Python deve-se à sua consolidação como padrão na comunidade de Inteligência Artificial, oferecendo robustez e suporte a bibliotecas científicas especializadas. Para a manipulação, carregamento e adaptação dos modelos pré-treinados, utiliza-se a biblioteca Hugging Face *transformers*, cuja arquitetura modular abstrai a complexidade de engenharia das redes neurais baseadas em Transformers e disponibiliza implementações otimizadas para a tarefa de *Question Answering* extrativo. Esta tarefa opera por meio de uma camada de classificação linear sobre os vetores finais do codificador, encarregada de prever os índices de início e término do segmento de texto que contém a resposta.

No que tange aos recursos de dados, empregam-se conjuntos derivados do padrão SQuADv2 adaptados para a língua portuguesa. Como a literatura aponta riscos associados a traduções automáticas brutas, o processo metodológico exige rigor na verificação da integridade dos intervalos (*spans*) textuais. Na divisão dos conjuntos de treinamento e validação, adota-se o cuidado de particionar os dados com base nos documentos de origem, prevenindo que passagens correlatas vazem entre os conjuntos e induzam o modelo a uma memorização em vez de generalização semântica.

Em termos arquiteturais, a investigação confronta o comportamento de modelos multilíngues e de modelos monolíngues especializados em português (como o NorBERTo). Para lidar com a restrição histórica de comprimento de entrada dos codificadores tradicionais, técnicas como janelas deslizantes (*sliding windows*) são tradicionalmente empregadas; contudo, o uso de arquiteturas recentes como o ModernBERT viabiliza o processamento de janelas de contexto estendidas de forma nativa. No caso do uso de modelos menores, o uso de janela deslizante é necessário.

A apuração quantitativa do desempenho é conduzida por meio da biblioteca *evaluate*, que padroniza o cálculo das métricas essenciais para QA extrativo: a correspondência exata (*Exact Match* - EM), que verifica se a resposta extraída coincide letra por letra com o gabarito, e o coeficiente F1 ao nível de *tokens*, que quantifica a sobreposição de termos entre a predição e a referência. Devido à restrição de acesso ao conjunto de teste oficial do SQuADv2, mantido em ambiente restrito para evitar vazamento de dados em competições, a validação final é realizada sobre um subconjunto isolado de validação extraído da base de dados disponível. A avaliação deve contemplar todas as restrições até então mencionadas, além de fielmente ser capaz de embasar o procedimento comparativo de transferência translíngue e tamanho de textos de entrada.

5 Cronograma

O cronograma de execução das atividades previstas para o desenvolvimento deste trabalho abrange o período entre setembro de 2026 e junho de 2027, contemplando desde o levantamento bibliográfico inicial, o desenvolvimento e os experimentos computacionais,

até a escrita e apresentação da monografia final. A distribuição detalhada das etapas está apresentada na Tabela 1.

Tabela 1: Cronograma detalhado de execução das atividades.

Atividade / Etapa	**Set 26**	**Out 26**	**Nov 26**	**Dez 26**	**Jan 27**	**Fev 27**	**Mar 27**	**Abr 27**	**Mai 27**	**Jun 27**
Levantamento bibliográfico e revisão da literatura	X	X								
Definição de tecnologias e primeiro *fine-tune*	X									
Definição de modelos e datasets de comparação			X	X						
Treinamento e avaliação comparativa de idiomas				X	X					
Avaliação comparativa de textos de entrada					X	X				
Análise dos resultados e elaboração de hipóteses						X	X			
Elaboração do anteprojeto e monografia parcial			X	X						
Escrita da monografia final					X	X	X	X	X	
Apresentação e defesa da monografia final										X

Referências

[1] Antonio Carlos Gil. *Como elaborar projetos de pesquisa*. Atlas, São Paulo, 4 edition, 2002.

[2] Nguyen Khang, Hien Nguyen, Thi-Thu-Trang Nguyen, Phuong Nguyen, Tung Le, and Le Nguyen. *A Novel Pipeline to Enhance Question-Answering Model by Identifying Relevant Information*, pages 296–311. 07 2023.

[3] Fahim Sufi and Ibrahim Khalil. Automated disaster monitoring from social media posts using ai-based location intelliggence and sentiment analysis. *IEEE Transactions on Computational Social Systems*, 11:4614–4624, 01 2022.