Avaliação sobre Capacidade de Transferência Translíngue em Inferência de Modelos de Linguagem ModernBERT voltada para QA Extrativo de Longo Contexto

Victor Hugo Santos Bitencourt
Departamento de Ciências Exatas e da Terra, Campus I
Universidade do Estado da Bahia (UNEB)
Salvador, Bahia, Brasil.
abjurandam@gmail.com

1 Introdução

No âmbito da Inteligência Artificial, os Grandes Modelos de Linguagem (LLMs) dominam o centro da discussão. No entanto, na pesquisa científica atual, outros tipos de modelos exibem avanços contínuos; em particular, modelos BERT *(Bidirectional encoder representations from transformers)* estão sempre no centro da discussão do campo de NLP (Processamento de Linguagem Natural), sendo utilizados para tarefas de classificação de texto, como análise de sentimento e reconhecimento de entidades nomeadas. Uma dessas tarefas consiste no *Question Answering* Extrativo, que se difere dos mecanismos de busca modernos (ex: RAG) por buscar informações diretamente no texto, retornando uma passagem, a partir de um *prompt,* sem recorrer a contexto externo [1]. Diversos trabalhos mostram numerosas aplicações de tarefas desempenhadas por modelos BERT; um trabalho mostra o QA Extrativo sendo utilizado para inferência de locais de desastres naturais em texto [2].

Tais modelos são elaborados sendo submetidos a um pré-treinamento em um conjunto geralmente massivo de dados, seguido de um processo de *fine-tuning* em um *dataset* para o desempenho de tarefas específicas. É importante destacar que, compreensivelmente, os modelos de fronteira, assim como a pesquisa em NLP como um todo, é preponderantemente debruçada tendo a língua inglesa como padrão universal. Nesse sentido, cabe o questionamento a respeito dos impactos dos idiomas dos dados de treinamento e *fine-tuning* no desempenho dos modelos em idiomas diversos, além do inglês. Afinal, há um vasto volume de modelos disponíveis publicamente, sejam em inglês, multilíngues, e nativos de outros idiomas, e os impactos dos idiomas utilizados nos treinamentos não é tão autoevidente.

Diante desse cenário, este trabalho visa investigar como esse efeito do idioma, sendo o modelo submetido a diferentes tamanhos de textos.

2 Objetivos

Investigar experimentalmente a influência do alinhamento linguístico e do tamanho da janela de contexto no desempenho de modelos baseados em arquiteturas BERT para tarefas de *Question Answering* (QA) extrativo em português, por meio da implementação de um ambiente experimental e da avaliação comparativa de diferentes modelos e configurações de inferência.

2.1 Objetivos Específicos

- Implementar um ambiente experimental para execução e avaliação de modelos BERT em tarefas de QA extrativo, contemplando o processamento dos conjuntos de dados, a preparação dos modelos e a execução das inferências.
- Selecionar e configurar modelos pré-treinados monolíngues e multilíngues, baseados na arquitetura *ModernBERT.*
- Implementar experimentos controlados que permitam variar o tamanho de texto de entrada e comparar o desempenho dos modelos em diferentes configurações de idioma, mantendo condições de avaliação consistentes.
- Avaliar quantitativamente os resultados obtidos, utilizando métricas consolidadas para QA extrativo, especialmente *Exact Match* (EM) e *token-level* F1, considerando as configurações experimentais.
- Analisar os resultados experimentais a fim de identificar os impactos do alinhamento linguístico e do tamanho do texto de entrada na qualidade das respostas extraídas, confrontando os resultados obtidos com as lacunas e evidências identificadas na literatura existente.

3 Justificativas e Contribuições

4 Metodologia

5 Cronograma

Referências

[1] Nguyen Khang, Hien Nguyen, Thi-Thu-Trang Nguyen, Phuong Nguyen, Tung Le, and Le Nguyen. *A Novel Pipeline to Enhance Question-Answering Model by Identifying Relevant Information*, pages 296–311. 07 2023.

[2] Fahim Sufi and Ibrahim Khalil. Automated disaster monitoring from social media posts using ai-based location intelligence and sentiment analysis. *IEEE Transactions on Computational Social Systems*, 11:4614–4624, 01 2022.