Transferência translíngue e contexto longo em modelos BERT para QA extrativo

Revisão Sistemática - TCC1

Victor Bitencourt

Universidade do Estado da Bahia (UNEB)

30 de Outubro de 2026

Objetivo de Pesquisa

Sintetizar evidências sobre transferência entre idiomas e tamanho de contexto em modelos BERT/encoder-only, com foco em QA extrativo e português.

Questões de Pesquisa

- Qual o estado da arte no QA Extrativo?
- Como o alinhamento entre a língua do pré-treinamento e do *fine-tuning* influencia o desempenho de modelos baseados em BERT em QA extrativo, entre outras tarefas *downstream?*
- Como a literatura caracteriza o desempenho qualitativo de modelos *encoder-only* monolíngues e multilíngues em tarefas de QA extrativo em português, dentre outras tarefas *downstream?*
- Qual é a influência do tamanho do texto a ser processado no desempenho qualitativo de modelos baseados em BERT para tarefas *downstream*, em particular o QA Extrativo?

O problema: responder bem em outra língua e em textos longos

QA extrativo

Dada uma pergunta e um texto, o modelo identifica e retorna o trecho que contém a resposta.

Transferência translíngue

Um modelo treinado em certos idiomas é aplicado a outro — por exemplo, do inglês para o português.

Contexto longo

O texto pode ultrapassar o limite máximo de caracteres suportado por modelos BERT, exigindo localizar evidências distantes.

Modelos de Perguntas e Respostas

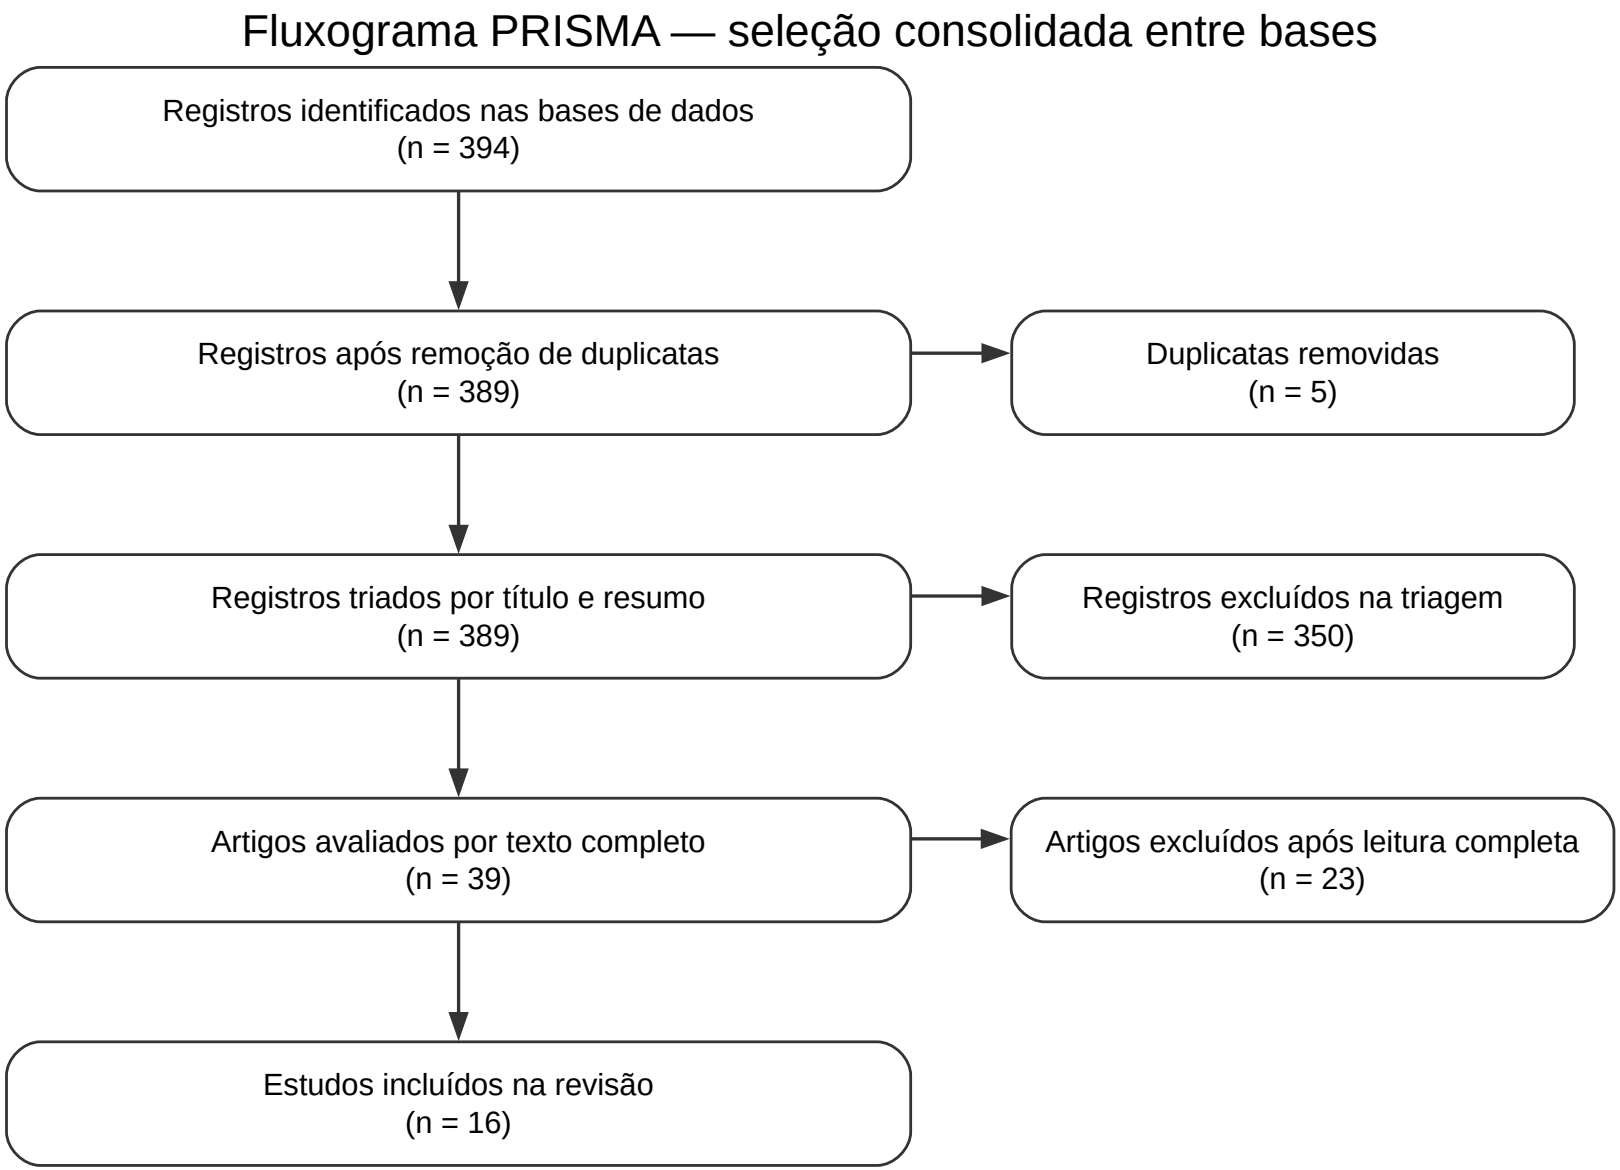
Modelos BERT *(encoder-only)*

Atenção bidirecional nativa sem perda de foco em tokens distantes. Alta precisão na delimitação de índices de respostas, menor latência e custo computacional reduzido sem risco de alucinações.

LLMs Generativos

Decaimento de atenção em trechos distantes durante a geração. Dificuldade empírica na identificação exata de spans de texto em tarefas formais de Question Answering Extrativo.

Seleção e Mapeamento dos Artigos



Seleção e Mapeamento dos Artigos

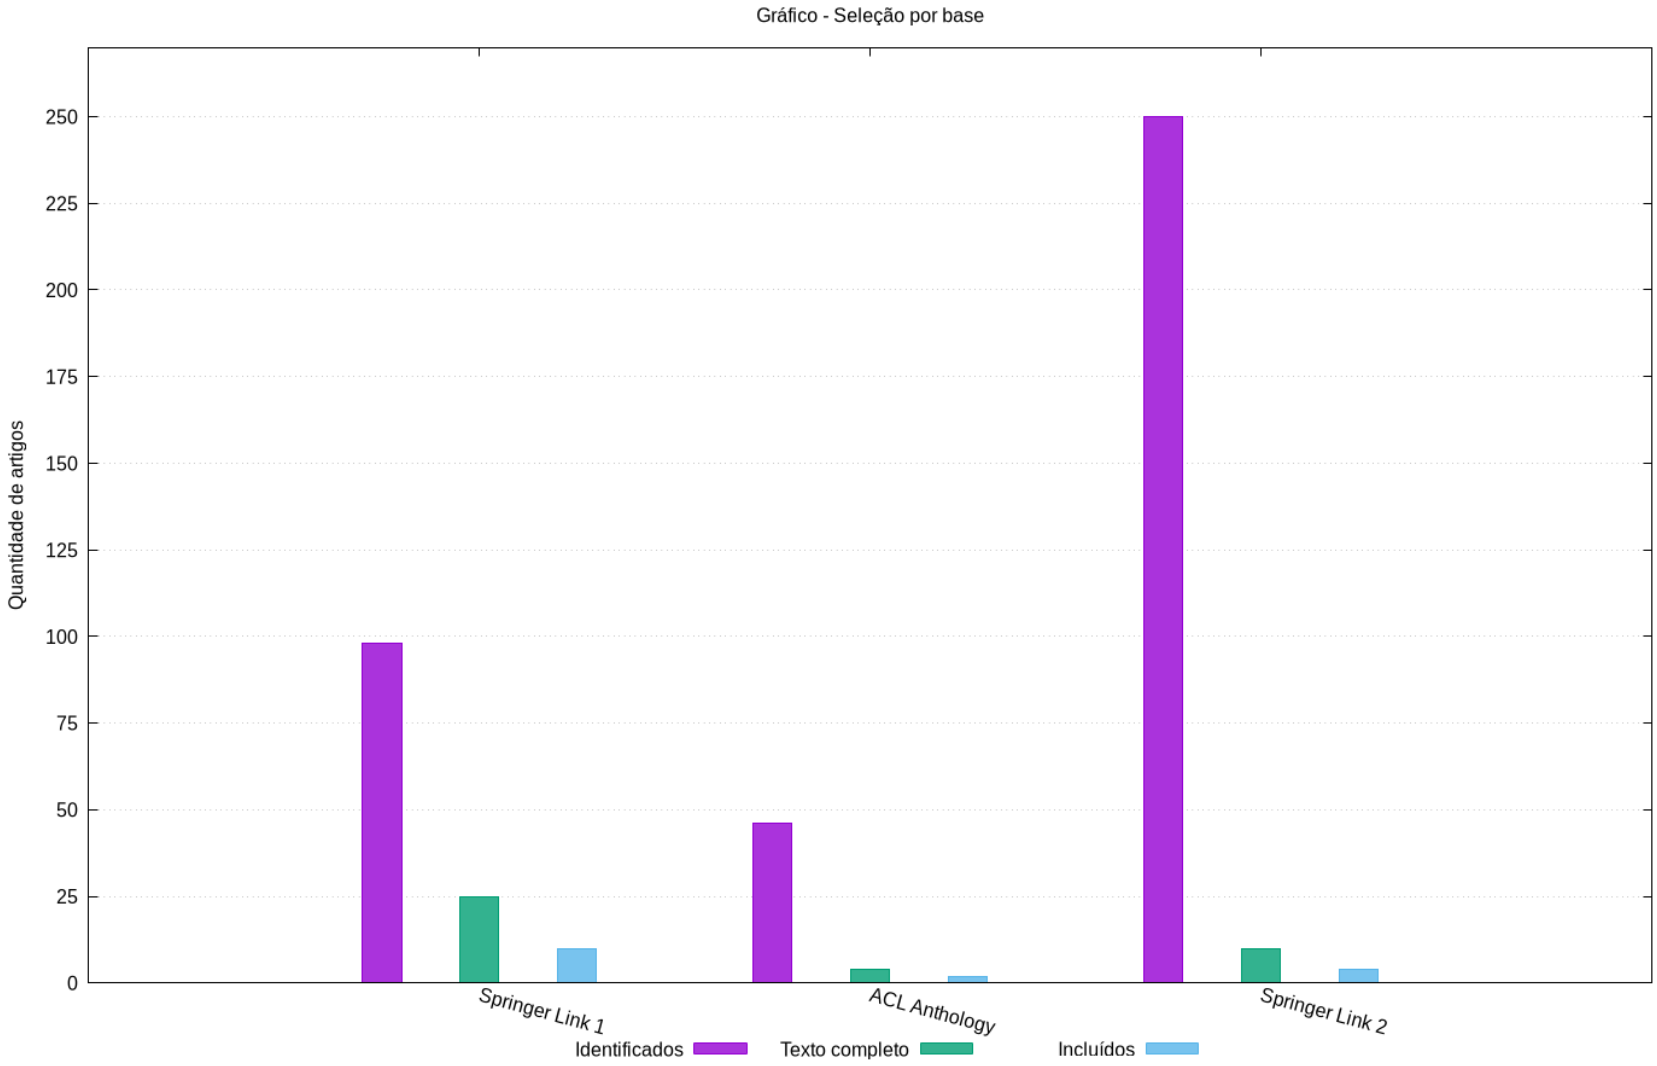


Figure 2: plot

QP1: Estado da Arte em QA Extrativo

Atenção Bidirecional Superior

Modelos encoder-only dominam benchmarks de QA extrativo por preservarem contexto completo sem perda de atenção em trechos distantes.

Métricas Padronizadas

A avaliação consolida-se através de Exact Match (EM) e token-level F1-score sobre datasets de referência como o SQuAD 2.0.

Escolha de Modelos

Modelos generativos apresentam imprecisão na identificação de índices exatos, tornando os encoders a escolha ideal para extração rígida de passagens.

QP2: A "Maldição da Multilingualidade"

Modelos Multilíngues (mBERT/XLM-R)

Permitem transferência para idiomas com baixos recursos computacionais ao capturar relações estruturais genéricas. Gargalo: Degradação de desempenho à medida que a quantidade de línguas cobertas aumenta.

Modelos Monolíngues Nativos

Especialização profunda no léxico e gramática local, superando modelos multilíngues de maior porte. Vantagem: Maior alinhamento em nuances culturais, termos regionais e linguagem informal.

QP3: Modelos Encoder-Only para a Língua Portuguesa

BERTimbau

Consolidou a superioridade monolíngue sobre modelos multilíngues em tarefas clássicas de inferência no português.

BERTomelo

Especializado com datasets jurídicos nativos (LeNER-Br), superando baselines em acurácia e Fl-score.

NorBERTO

Baseado em ModernBERT e treinado em 331B tokens; destaca-se pela alta eficiência mesmo com menor contagem de parâmetros.

Importante destacar que parte dessa evidência vem de tarefas relacionadas, como NER ou classificação, não exclusivamente de QA extrativo.

QP4: O Desafio do Processamento de Longos Contextos

Potencial Teórico

Mecanismos de self-attention bidirecional distribuem a relevância semântica uniformemente ao longo do texto.

Limitação Empírica

Excesso de detalhes ruidosos (“muitos detalhes”) pode prejudicar a precisão da extração em documentos extensos.

Contexto longo segue como lacuna, devido a evidência ainda insuficiente especialmente para QA Extrativo.

Síntese de Evidências

Fortes

Transferência multilíngue é possível; alinhamento do idioma influencia o desempenho; modelos nativos podem superar multilíngues.

Indiretas

Resultados de NER e classificação ajudam a contextualizar; benchmarks traduzidos podem introduzir ruído; vantagens de BERT dependem da tarefa e da avaliação.

Lacunas Abertas

Poucos estudos combinam QA extrativo, português e contexto longo; falta comparação controlada entre janelas de contexto; ModernBERT merece avaliação empírica específica.

Avaliação de Janelas Expandidas

Investigar empiricamente o comportamento do QA extrativo sob janelas de 8192 tokens no ModernBERT, variando tamanhos de entradas.

Datasets Nativos em Português

Investigar conjuntos de dados de QA de longo contexto não traduzidos para o idioma luso-brasileiro.

Métricas

Usar EM e F1.

Português + QA extrativo + janelas longas formam uma lacuna de pesquisa relevante.