Transferência translíngue e contexto longo em modelos BERT para QA extrativo

Revisão Sistemática - TCC1

Victor Bitencourt

Universidade do Estado da Bahia (UNEB)

30 de Outubro de 2026

Objetivo de Pesquisa

Sintetizar evidências sobre transferência entre idiomas e tamanho de contexto em modelos BERT/encoder-only, com foco em QA extrativo e português.

Questões de Pesquisa

- Qual o estado da arte no QA Extrativo?
- Como o alinhamento entre a língua do pré-treinamento e do *fine-tuning* influencia o desempenho de modelos baseados em BERT em QA extrativo, entre outras tarefas *downstream?*
- Como a literatura caracteriza o desempenho qualitativo de modelos *encoder-only* monolíngues e multilíngues em tarefas de QA extrativo em português, dentre outras tarefas *downstream?*
- Qual é a influência do tamanho do texto a ser processado no desempenho qualitativo de modelos baseados em BERT para tarefas *downstream*, em particular o QA Extrativo?

The models selected in this study represent different transformer-based learning paradigms that are suitable for low-resource language processing. Multilingual models, namely mBERT and XLM-RoBERTa, were selected because of their ability to leverage cross-lingual transfer learning. These models have performed well in low-resource language settings[4–6]. To evaluate the impact of pretraining the Burmese language in a language-specific manner, Burmese RoBERTa was selected. To investigate the possibility of local feature extraction to supplement transformer-based features when classifying fake news, a hybrid framework consisting of XLM-RoBERTa and CNN was employed. This study contrasts these four fake news detectors that use transformers in the Burmese language in a limited data setup. All models were trained based on the same preprocessing techniques, hyperparameters, and metrics to ensure fair and controlled comparisons.

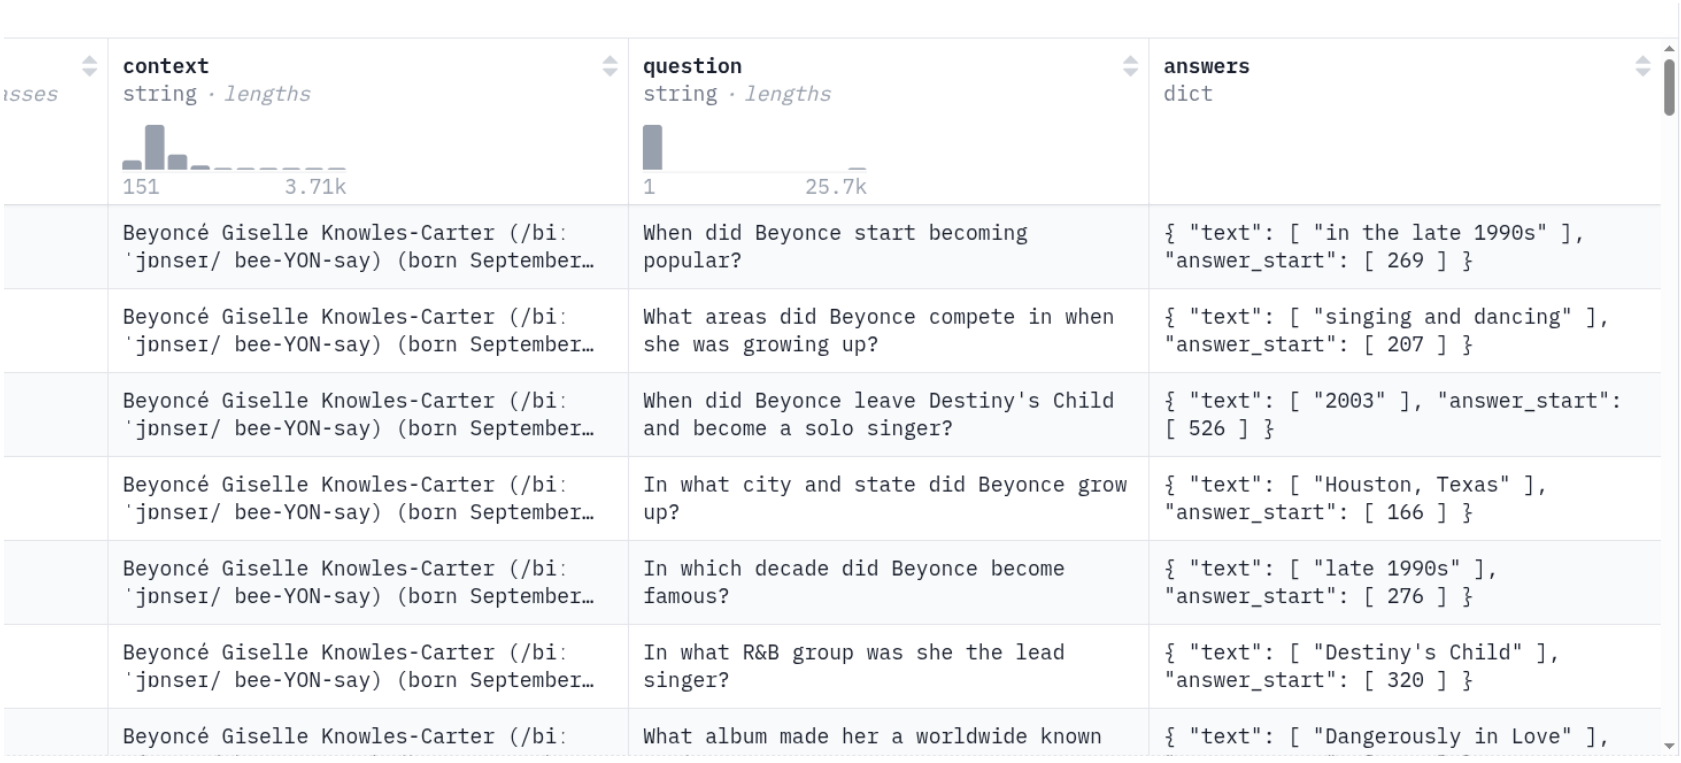
The training parameters used for all models are listed in Table 3. Identical hyperparameters were applied across all the architectures to ensure consistency and experimental fairness. The AdamW optimizer was used because of its effectiveness in fine-tuning large transformer models. Its decoupled weight decay helps reduce overfitting[29]. A low learning rate was adopted to stabilize the convergence under limited data conditions.

Transformer-based models significantly outperform conventional machine learning approaches in fake news detection as presented by[30]. The authors used DistilBERT, which achieved an accuracy as high as 99.91%. Based on these findings, all transformer models in this study were initialized with pretrained weights and fine-tuned end-to-end on the Burmese dataset. A dropout rate of 0.2 was applied before the final classification layer to reduce overfitting, which may have resulted from the relatively small dataset. Binary classification was performed using a SoftMax output layer with a cross-entropy loss.

Table 4 presents the architectural details of all the evaluated models. All models used normalized Burmese headlines with a fixed maximum input-sequence length to ensure a consistent input representation.

The hyperparameter tuning strategy and training settings used for all models are summarized in Table 5. A cosine annealing learning rate scheduler was used to gradually reduce the learning rate and ensure a smooth convergence. Gradient clipping was applied to stabilize the optimization and prevent exploding gradients. All the models were evaluated using the same metrics. This ensures that the performance differences are attributable solely to the model design rather than experimental variations.

Figura 1: Fonte: Chandraparsad et al.



ısses	context string · *lengths* 151 3.71k	question string · *lengths* 1 25.7k	answers dict
	Beyoncé Giselle Knowles-Carter (/biːˈjɒnseɪ/ bee-YON-say) (born September…	When did Beyonce start becoming popular?	{ "text": ["in the late 1990s"], "answer_start": [269] }
	Beyoncé Giselle Knowles-Carter (/biːˈjɒnseɪ/ bee-YON-say) (born September…	What areas did Beyonce compete in when she was growing up?	{ "text": ["singing and dancing"], "answer_start": [207] }
	Beyoncé Giselle Knowles-Carter (/biːˈjɒnseɪ/ bee-YON-say) (born September…	When did Beyonce leave Destiny's Child and become a solo singer?	{ "text": ["2003"], "answer_start": [526] }
	Beyoncé Giselle Knowles-Carter (/biːˈjɒnseɪ/ bee-YON-say) (born September…	In what city and state did Beyonce grow up?	{ "text": ["Houston, Texas"], "answer_start": [166] }
	Beyoncé Giselle Knowles-Carter (/biːˈjɒnseɪ/ bee-YON-say) (born September…	In which decade did Beyonce become famous?	{ "text": ["late 1990s"], "answer_start": [276] }
	Beyoncé Giselle Knowles-Carter (/biːˈjɒnseɪ/ bee-YON-say) (born September…	In what R&B group was she the lead singer?	{ "text": ["Destiny's Child"], "answer_start": [320] }
	Beyoncé Giselle Knowles-Carter (/biː	What album made her a worldwide known	{ "text": ["Dangerously in Love"],

Figura 2: Fonte: HuggingFace.

O problema investigado: responder bem em outra língua e em textos longos

QA extrativo

Dada uma pergunta e um texto, o modelo identifica e retorna o trecho que contém a resposta.

Transferência translíngue

Um modelo treinado em certos idiomas é aplicado a outro; por exemplo, do inglês para o português.

Contexto longo

O texto pode ultrapassar o limite máximo de caracteres suportado por modelos BERT, exigindo localizar evidências distantes.

Modelos de Perguntas e Respostas

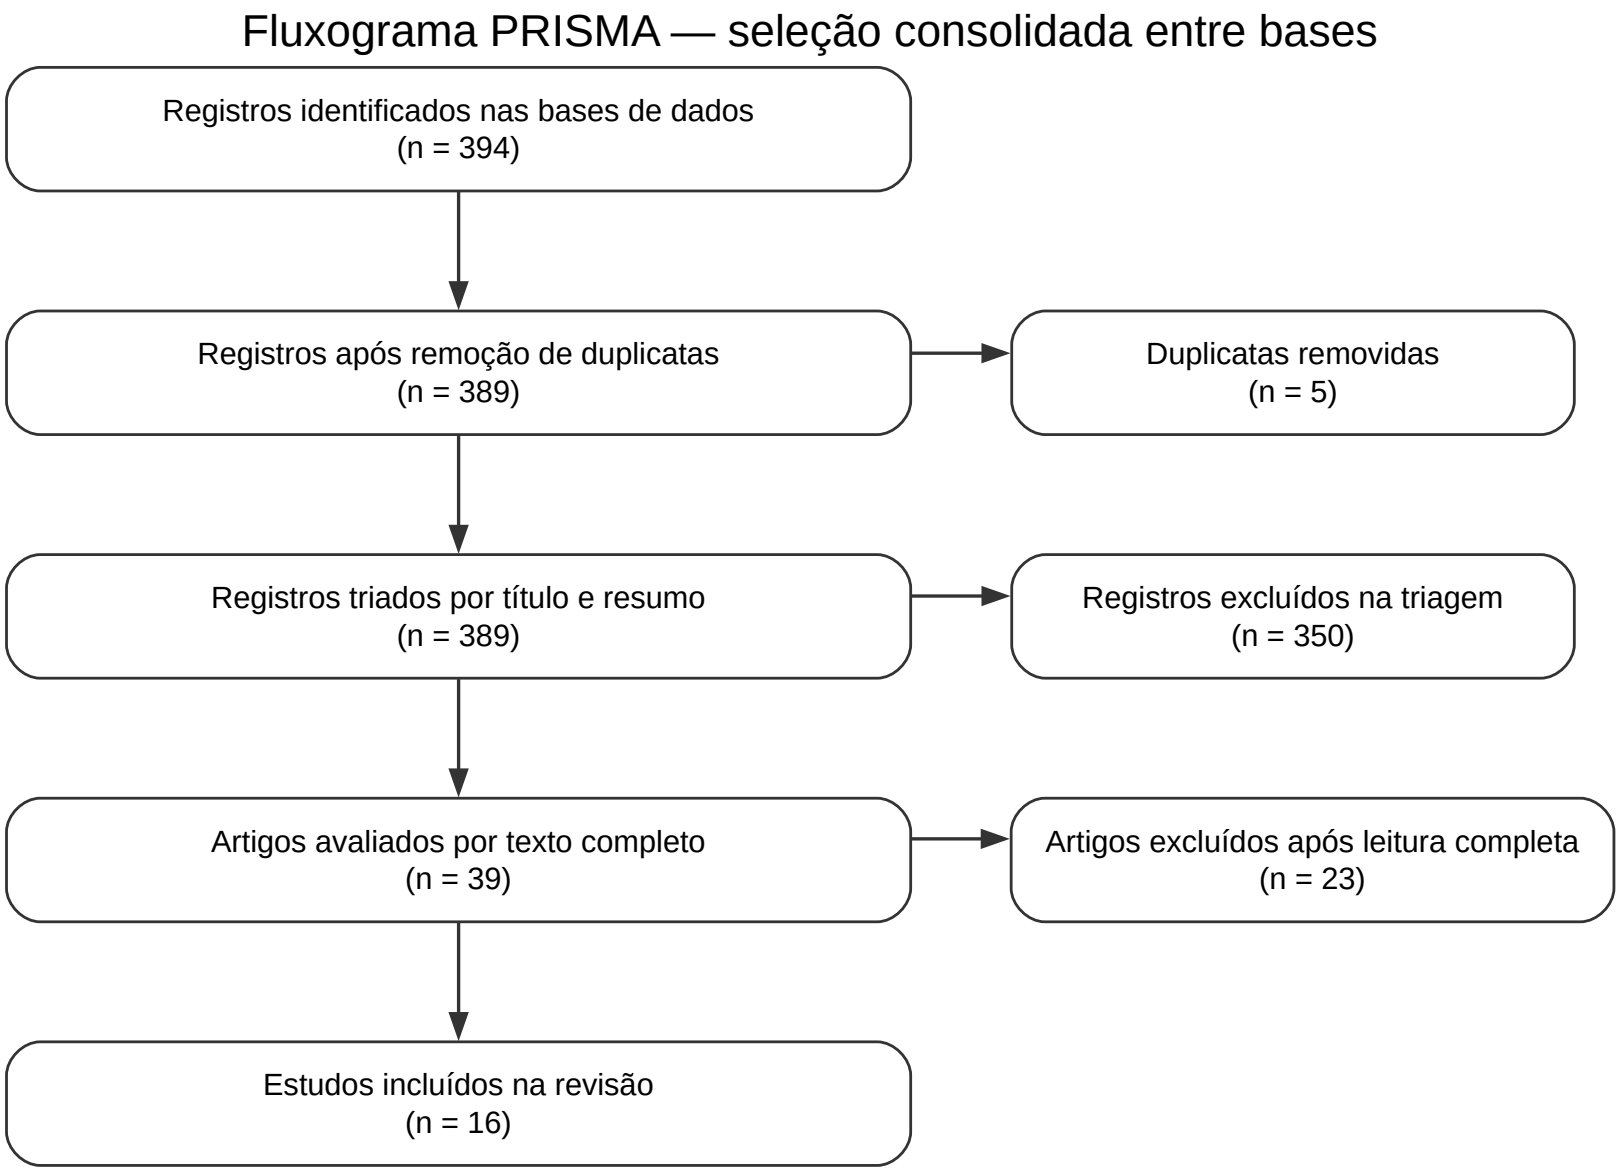
Modelos BERT *(encoder-only)*

Atenção bidirecional nativa sem perda de foco em tokens distantes. Alta precisão na delimitação de índices de respostas, menor latência e custo computacional reduzido sem risco de alucinações.

LLMs Generativos

Decaimento de atenção em trechos distantes durante a geração. Dificuldade empírica na identificação exata de spans de texto em tarefas formais de Question Answering Extrativo.

Seleção e Mapeamento dos Artigos



Seleção e Mapeamento dos Artigos

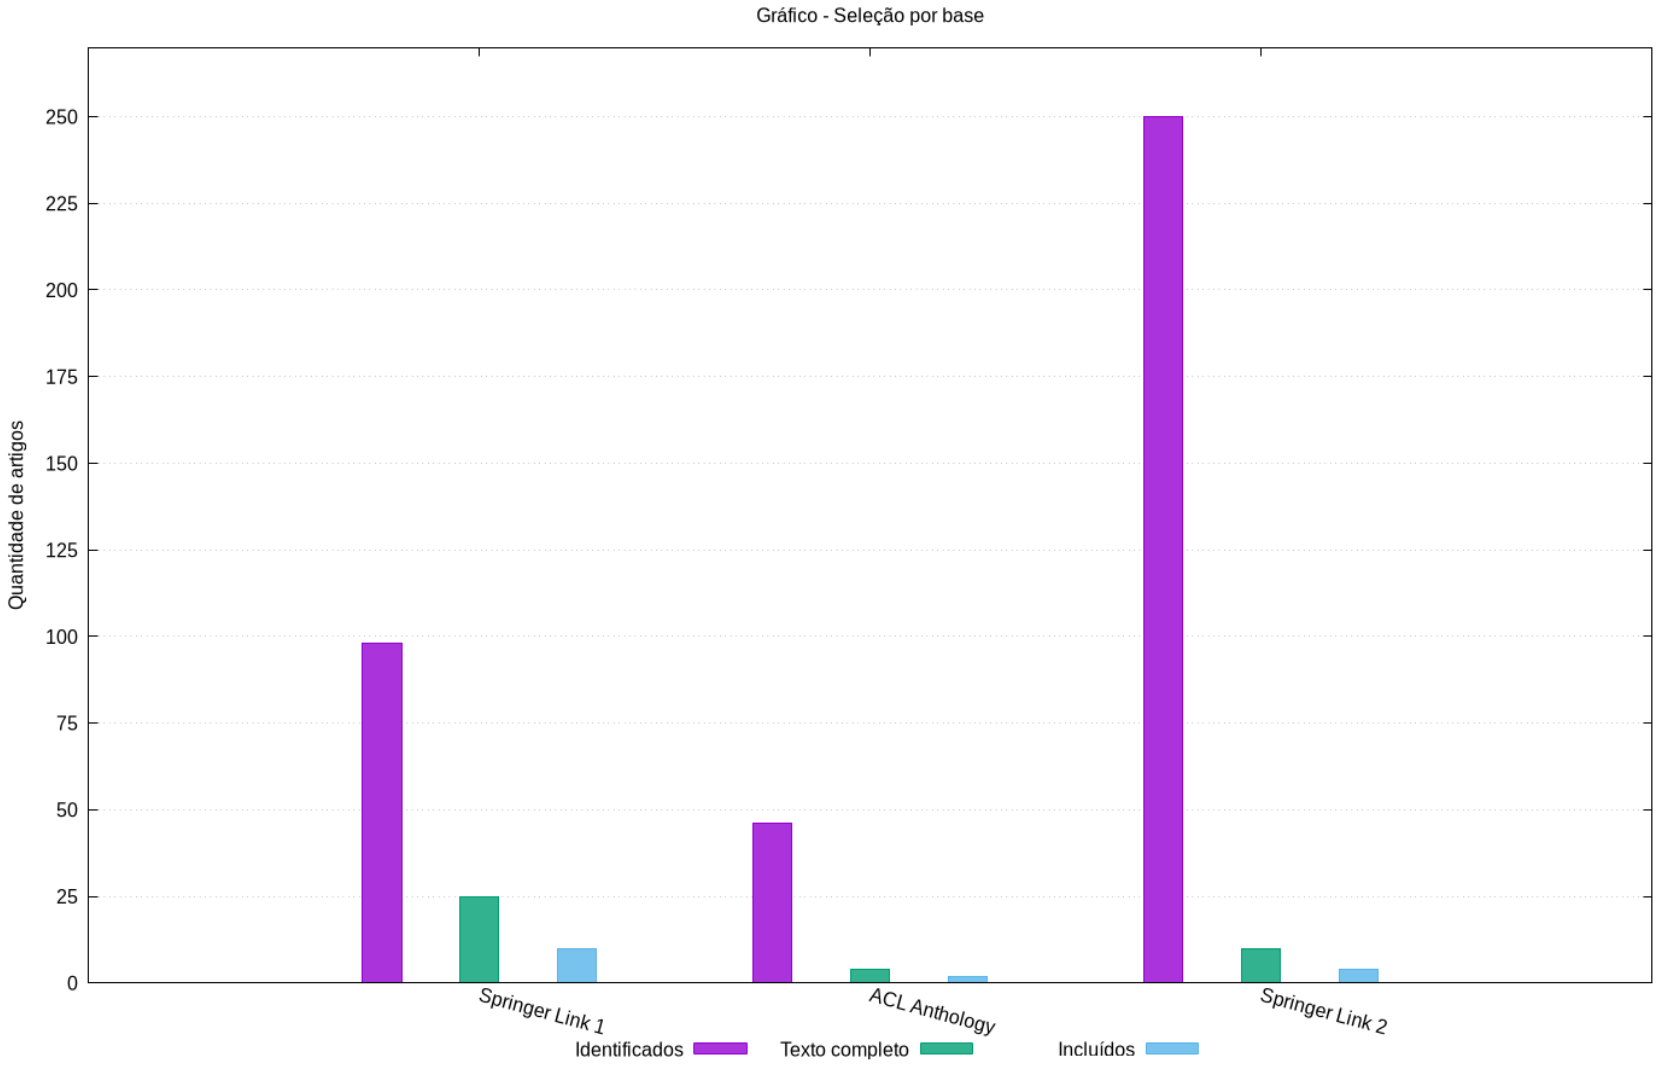


Figura 4: Fonte: o autor

QP1: Estado da Arte em QA Extrativo

Atenção Bidirecional Superior

Modelos encoder-only dominam benchmarks de QA extrativo por preservarem contexto completo sem perda de atenção em trechos distantes.

Métricas Padronizadas

A avaliação consolida-se através de Exact Match (EM) e token-level F1-score sobre datasets de referência como o SQuAD 2.0.

Escolha de Modelos

Modelos generativos apresentam imprecisão na identificação de índices exatos, tornando os encoders a escolha ideal para extração rígida de passagens.

QP2: A "Maldição da Multilingualidade"

Modelos Multilíngues (mBERT/XLM-R)

Permitem transferência para idiomas com baixos recursos computacionais ao capturar relações estruturais genéricas. Gargalo: Degradação de desempenho à medida que a quantidade de línguas cobertas aumenta.

Modelos Monolíngues Nativos

Especialização profunda no léxico e gramática local, superando modelos multilíngues de maior porte. Vantagem: Maior alinhamento em nuances culturais, termos regionais e linguagem informal.

QP3: Modelos Encoder-Only para a Língua Portuguesa

BERTimbau

Consolidou a superioridade monolíngue sobre modelos multilíngues em tarefas clássicas de inferência no português.

BERTomelo

Especializado com datasets jurídicos nativos (LeNER-Br), superando baselines em acurácia e Fl-score.

NorBERTO

Baseado em ModernBERT e treinado em 331B tokens; destaca-se pela alta eficiência mesmo com menor contagem de parâmetros.

Importante destacar que parte dessa evidência vem de tarefas relacionadas, como NER ou classificação, não exclusivamente de QA extrativo.

QP4: O Desafio do Processamento de Longos Contextos

Potencial Teórico

Mecanismos de self-attention bidirecional distribuem a relevância semântica uniformemente ao longo do texto.

Limitação Empírica

Excesso de detalhes ruidosos (“muitos detalhes”) pode prejudicar a precisão da extração em documentos extensos.

Contexto longo segue como lacuna, devido a evidência ainda insuficiente especialmente para QA Extrativo.

Síntese de Evidências

Fortes

Transferência multilíngue é possível; alinhamento do idioma influencia o desempenho; modelos nativos podem superar multilíngues.

Indiretas

Resultados de NER e classificação ajudam a contextualizar; benchmarks traduzidos podem introduzir ruído; vantagens de BERT dependem da tarefa e da avaliação.

Lacunas Abertas

Poucos estudos combinam QA extrativo, português e contexto longo; falta comparação controlada entre janelas de contexto; ModernBERT merece avaliação empírica específica.

Avaliação de Janelas Expandidas

Investigar empiricamente o comportamento do QA extrativo sob janelas de 8192 tokens no ModernBERT, variando tamanhos de entradas.

Datasets Nativos em Português

Investigar conjuntos de dados de QA de longo contexto não traduzidos para o idioma luso-brasileiro.

Métricas

Usar EM e F1.

Português + QA extrativo + janelas longas formam uma lacuna de pesquisa relevante.

Referências

https://huggingface.co/datasets/rajpurkar/squad_v2/viewer

., C., Kyaw, K.T., Jain, R. et al. A systematic evaluation of transformer-based architectures for fake news detection in the low-resource Burmese language. Sci Rep 16, 25667 (2026). https://doi.org/10.1038/s41598-026-56647-7