Revisão Sistemática sobre Capacidade de Transferência Entre Idiomas em Inferência de Modelos de Linguagem BERT voltada para QA Extrativo de Longo Contexto

Victor Hugo Santos Bitencourt
Departamento de Ciências Exatas e da Terra, Campus I
Universidade do Estado da Bahia (UNEB)
Salvador, Bahia, Brasil.
abjurandam@gmail.com

Resumo

Este trabalho consiste em uma revisão sistemática a sobre tal coisa, buscando investigar tal coisa. A metodologia consistiu em fazer tais coisas. Os resultados consistem em tais coisas. Conclui-se que tal coisa.

Abstract

Em inglês.

1 Introdução

No contexto do que, esse tema principal serve pra tal coisa. Qual sua importancia, relevancia, normas tecnicas? O que é esse tema principal, de acordo com tal norma tecnica? Cite alguma coisa pra nao ficar no ar. Traga o contexto do mundo, do Brasil, seja o que for.

Traga, por gentileza, a motivação do problema. Onde mora o problema? Tipo... essa área traz tais demandas, mas tal problema existe. Pode ser feito de tal jeito, mas aí tais problemas surgem. (Isso é a base pra introduzir sua solução). Traga umas definições pra já ir acostumando o leitor. Introduza termos técnicos bem de leve, os bem gerais mesmo.

Nesse cenário, essas coisas novas surgiram pra trazer tal e tal benefício. Mas tem porém, tal e tal coisa acontece. Cite algo. Assim, surge a necessidade de fazer pipipi popopo do seu jeito. "A motivação da pesquisa surge na necessidade de investigar essas lacunas".

No ecossistema X, sua solução se manifesta de tal forma e pode ser usada de tal forma. Isso, já vai dando sinais de sua metodologia. Contudo, tais limitações etc etc: não combina ou usa tais coisas, o que limita os ganhos. Logo, essa revisão tem como objetivo "mapear e analisar métodos já estudados, buscando fundamentos para a construção integrada X". Essa Revisão Sistemática de Literatura (RSL) busca identificar (liste tudo), "práticas, mecanismos" para esse objetivo específico. Seja completo logo.

2 Relato da Revisão de Literatura

Escreva alguma coisa.

2.1 Questões de Pesquisa

Escreva algo

2.2 Definição do PICOC

Escreva alguma coisa.

- Population (População):
- Intervention (Intervenção):
- Comparison (Comparação):
- Outcome (Resultado):
- Context (Contexto):

2.3 Critérios de Inclusão e Exclusão

Escreva algo aqui

2.4 Bases de Dados

As buscas foram feitas nos repositórios de artigos *Springer Link* e *ACL Anthology*. A primeira busca foi realizada no *Springer Link*, base que se mostrou promissora em volume de conteúdo para os temas estudados, com recorte temporal de 6 meses. A busca no *ACL Anthology* foi motivada pela busca de uma base mais alinhada com o campo de pesquisa em NLP, e os resultados foram acessados via *Google Scholar*. A terceira busca foi feita no *Springer Link*, sem recorte temporal, utilizando uma *string* de busca mais bem delimitada ao que se deseja pesquisar nesta revisão.

2.5 Strings de Busca

String de busca geral, utilizada no *Springer Link,* com escopo geral:

```
("BERT" OR "encoder-only transformer")
AND
("extractive question answering" OR "question answering" OR
"machine reading comprehension")
AND
("long context" OR "long-context" OR "long document" OR "context window"
OR "sequence length")
AND
(Portuguese OR multilingual OR monolingual OR "language-specific")
```

String utilizada no *Google Scholar* filtrando resultados do *ACL Anthology:*

```
"BERT" question answering "multilingual" "context size"
cross-lingual transfer site:aclanthology.org
```

String utilizada por fim, no *Springer Link:*

```
"cross-lingual transfer" AND "BERT" AND "fine-tuning" AND NOT "LLM"
```

2.6 Perguntas de Avaliação de Qualidade

Escreva

2.7 Condução

A condução desta revisão sistemática dá-se a partir da coleta de artigos da base correspondente, realizada a partir de uma *string* de busca formulada a partir das questões de pesquisa e o PICOC. Os artigos duplicados são removidos, e a triagem inicial é realizada, que consiste numa leitura de título e resumo, aplicando os critérios de inclusão e exclusão.

O segundo passo se dá a partir da leitura completa dos artigos retornados, também seguindo os critérios de inclusão e exclusão e registrando-os. No mesmo momento é feito o registro da nota dada ao artigo com base nos critérios de inclusão (ponto positivo) e exclusão (ponto negativo), assim como a anotação de informações que dialogam com tanto com os critérios quanto com as perguntas de pesquisa. Foi definido que, ao final de toda a revisão, seriam considerados aceitos os artigos com nota maior que zero.

Por fim, para a base na qual foi feita a busca, foi feita uma avaliação rápida se o conteúdo apreendido traz progresso evidente na resposta das perguntas de pesquisa. Se não, o processo é repetido reformulando as perguntas de pesquisa e PICOC a fim de construir uma nova *string* de busca, potencialmente em outra base, seguida da pesquisa. Foi dessa forma que esse trabalho se valeu de mais de um método de busca e repositório de artigos, adotando uma postura investigativa e crítica sobre o tema em questão, e sobretudo a metodologia adotada para buscar o conhecimento.

3 Resultados das Triagens

Foram removidos 5 artigos duplicados. As 3 buscas, correspondentes a 2 bases, retornaram no total 394 resultados de pesquisa (soma de 389 artigos encontrados no total e 5 resultados duplicados). Após triagem por título e resumo, sobraram 39 artigos. Após leitura por texto completo, restaram 16 artigos, que logo em seguida tiveram seus dados extraídos após a análise individual dos critérios de inclusão e exclusão.

Por base, a primeira busca no *Springer Link* retornou 98 trabalhos, sendo 25 passados para leitura completa, e 10 aceitos. A segunda busca, no *ACL Anthology* retornou 46 resultados, tendo 4 sido lidos inteiramente e 2 aceitos. A terceira busca, também no *Springer Link*, trouxe 250 artigos, com 5 duplicados, 10 lidos na totalidade e 4 aceitos. Os resultados da triagem são mostrados a seguir, assim como o fluxograma da busca consolidada entre as bases.

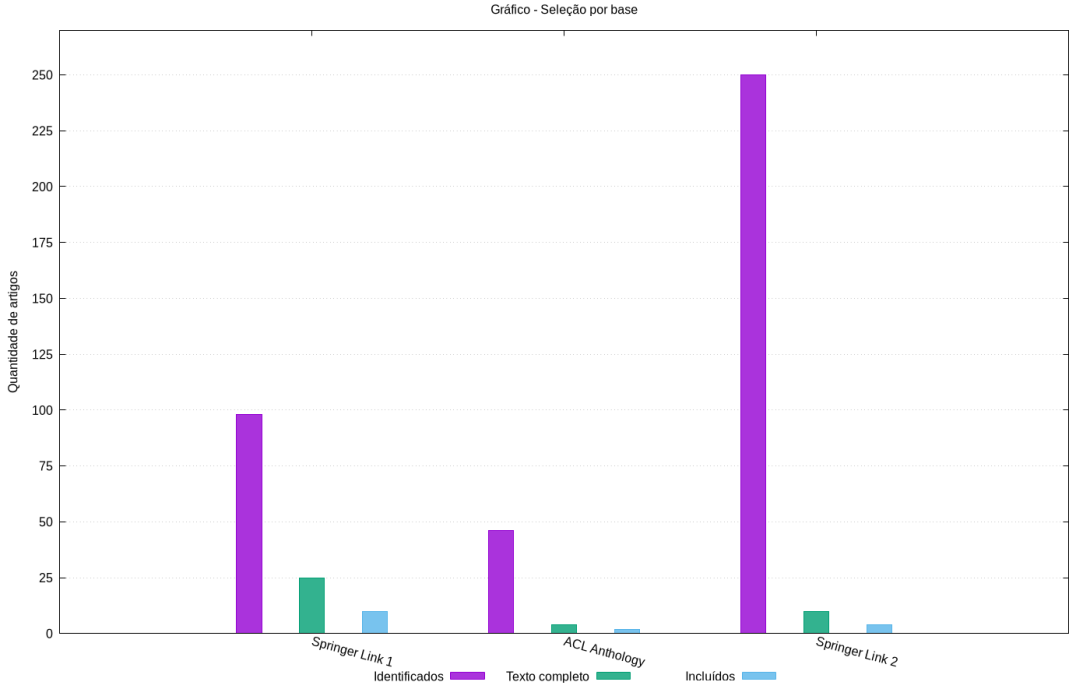


Figura 1: Gráfico de Resultados por Base

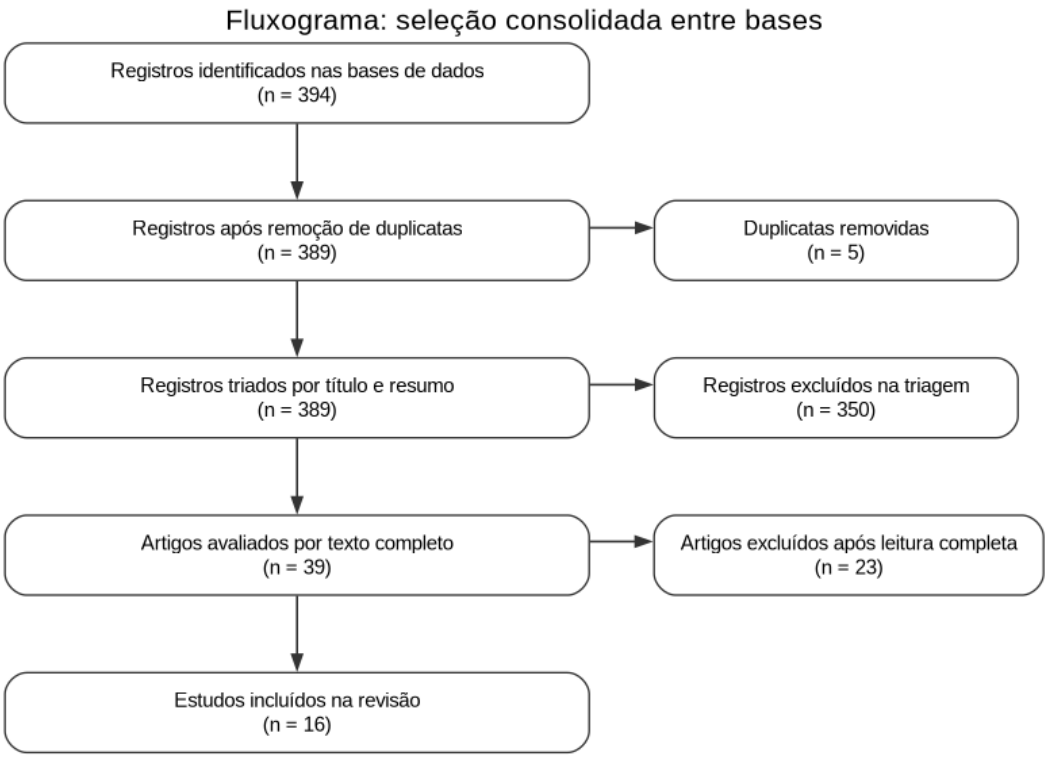


Figura 2: Fluxograma de seleção e triagem consolidada de artigos

Os artigos aceitos, suas respectivas identificações, critérios observados e anotações, podem ser vistos na tabela-resumo em anexo.

3.1 Análise Qualitativa dos Resultados

Escreva algo e cite [1].

4 Conclusões

Suas conclusões.

Referências

[1] W3C. Html5 specification. https://www.w3.org/TR/html5/, 2023.

5 Planilha-resumo dos Resultados

Tabela 1: Planilha-resumo dos trabalhos selecionados

Trabalho	I1	I2	I3	I4	I5	E1	E2	E3	E4	Observações
Ambala et al. (2026)	X	X	X		X					Discute a importância de *datasets* nativos em vez de traduções automáticas; aponta que a menor representação de certos idiomas no treinamento pode afetar a qualidade da inferência; considera o alinhamento uma precondição para a transferência bem-sucedida.
Alves Oliveira et al. (2026)	X	X	X	X						Apresenta a "maldição da multilingualidade", afirmando a superioridade de modelos monolíngues para tarefas em idoma nativo em comparação com multilíngues, com exemplos, e contextualiza na língua portuguesa. Com modelo baseado em *ModernBERT* com 1024 *tokens*, o BERTomelo, apresenta que longo contexto é um objeto de estudo a ser pesquisado em trabalhos futuros.
Savant et al. (2026)	X	X			X					QA Extrativo é um tipo especial de QA dentre muitos, no qual o BERT se destaca, e o mais sensível a problemas de tradução. Métricas principais: EM e *token-level* F1. Idiomas menos representados no treinamento de modelos multilíngues são prejudicados. SQuAD é um excelente dataset que acelera o desenvolvimento em contraste com *datasets* nativos bem menores, mas tradução automática pode comprometê-lo. O principal problema é o alinhamento de *spans*.
Sharma et al. (2026)	X		X		X					Mostra o QA Extrativo em uma aplicação específica: inferir locais de desastres naturais. Apresenta modelo de classificação desempenhando QA bem sem precisar de *fine-tuning* naquele contexto específico.
Enzo S. N. Silva et al. (2026)	X		X	X						Em comparação com LLMs, modelos BERT têm vantagens de custo, latência e não estarem expostos a alucinações, sendo tão bons ou até melhores para muitas tarefas. Sugere que modelos nativos, como BERTimbau em português, superaram multilíngues em diversas tarefas. Apresenta um modelo baseado em ModernBERT, o NorBERTo, que performa bem, mesmo não sendo pré-treinado em tanto conteúdo quando o ModernBERT original.
Ramy Eskander et al. (2026)	X	X	X							Mostra de forma detalhada um benchmark de *fine-tuning* de modelos de classificação para NER *(Named Entity Recognition)*. Compara modelos nativos, multilíngues em famílias de idiomas, e multilíngues em idiomas de origens diversas, uma categoria se sobressaindo à outra, respectivamente.
Villegas-Ch et al. (2026)	X	X	X							Desambigua termos: idioma *low-resource* e *less-represented*. Traz limitações a respeito de modelos multilígues terem limitações, notadamente no que diz respeito ao desempenho em linguagem informal ou regional, o que *benchmarks* comuns não mostram, notadamente no idioma português.