Revisão Sistemática sobre Capacidade de Transferência Translíngue em Inferência de Modelos de Linguagem BERT voltada para QA Extrativo de Longo Contexto

Victor Hugo Santos Bitencourt
Departamento de Ciências Exatas e da Terra, Campus I
Universidade do Estado da Bahia (UNEB)
Salvador, Bahia, Brasil.
abjurandam@gmail.com

Resumo

Este trabalho consiste em uma revisão sistemática a sobre tal coisa, buscando investigar tal coisa. A metodologia consistiu em fazer tais coisas. Os resultados consistem em tais coisas. Conclui-se que tal coisa.

Abstract

Em inglês.

1 Introdução

No contexto do que, esse tema principal serve pra tal coisa. Qual sua importancia, relevancia, normas tecnicas? O que é esse tema principal, de acordo com tal norma tecnica? Cite alguma coisa pra nao ficar no ar. Traga o contexto do mundo, do Brasil, seja o que for.

Traga, por gentileza, a motivação do problema. Onde mora o problema? Tipo... essa área traz tais demandas, mas tal problema existe. Pode ser feito de tal jeito, mas aí tais problemas surgem. (Isso é a base pra introduzir sua solução). Traga umas definições pra já ir acostumando o leitor. Introduza termos técnicos bem de leve, os bem gerais mesmo.

Nesse cenário, essas coisas novas surgiram pra trazer tal e tal benefício. Mas tem porém, tal e tal coisa acontece. Cite algo. Assim, surge a necessidade de fazer pipipi popopo do seu jeito. "A motivação da pesquisa surge na necessidade de investigar essas lacunas".

No ecossistema X, sua solução se manifesta de tal forma e pode ser usada de tal forma. Isso, já vai dando sinais de sua metodologia. Contudo, tais limitações etc etc: não combina ou usa tais coisas, o que limita os ganhos. Logo, essa revisão tem como objetivo "mapear e analisar métodos já estudados, buscando fundamentos para a construção integrada X".

Essa Revisão Sistemática de Literatura (RSL) busca identificar (liste tudo), "práticas, mecanismos" para esse objetivo específico. Seja completo logo.

Explicar como funciona o uso e avaliação do QA Extrativo.

O QA Extrativo pode ser utilizado em aplicações específicas: inferir locais de desastres naturais [8].

O português não é um idioma *low-resource,* mas sim *less-represented* [9].

Definição de QA tradicional e moderno (similares a RAG): [3]

Conceito de *Machine Reading Comprehension* [5]

2 Relato da Revisão de Literatura

2.1 Questões de Pesquisa

- Qual o estado da arte no *Question Answering* Extrativo?
- Como o alinhamento entre a língua do pré-treinamento e do fine-tuning influencia o desempenho de modelos baseados em BERT em *Question Answering* extrativo, entre outras tarefas *downstream?*
- Como a literatura caracteriza o desempenho qualitativo de modelos encoder-only monolíngues e multilíngues em tarefas de *Question Answering* extrativo em português, dentre outras tarefas *downstream?*
- Qual é a influência do tamanho do texto a ser processado no desempenho qualitativo de modelos baseados em BERT para tarefas *downstream,* em particular o QA Extrativo?

2.2 Definição do PICOC

Foi utilizado o *framework* PICOC para auxiliar na elaboração de *strings* de busca e busca do entendimento do tema. Cada elemento do PICOC fica explicitado a seguir.

- Population (População): Modelos baseados em BERT/Transformers encoder-only aplicados a *Question Answering* extrativo.
- Intervention (Intervenção): Uso de janelas de contexto maiores e/ou modelos pré-treinados em língua específica, com fine-tuning e avaliação alinhados ao idioma.
- Comparison (Comparação): Modelos multilíngues, modelos com menor janela de contexto e/ou modelos cujo pré-treinamento não é especializado na língua da tarefa.
- Outcome (Resultado): Desempenho em QA extrativo, especialmente métricas relacionadas ao desempenho sob diferentes tamanhos de contexto.
- Context (Contexto): *Question Answering* extrativo, com ênfase em textos longos e idiomas diferentes, particularmente português.

2.3 Critérios de Inclusão e Exclusão

Foram definidos critérios a fim de filtrar temas que estivessem mais alinhados ao assunto que se busca na pesquisa. Os critérios compõem juntos uma nota a ser utilizada posteriormente. No total, consistem em 5 critérios de inclusão e 4 critérios de exclusão.

- Critérios de Inclusão:
  - Foco no campo de estudo de NLP.
  - Trabalhos que tratam de forma concreta o assunto de inferência translíngue.
  - Foco em modelos BERT ou *encoder-only.*
  - Trabalhos que tocam no tema de processamento de longos contextos.
  - Trata diretamente de QA Extrativo.
- Critérios de Exclusão:
  - Desvio de domínio: assunto ou área de estudo do artigo se desvia consideravelmente do foco da pesquisa.
  - Foco em modelos não-BERT ou *encoder-only:* LLMs, CNNs, LSTMs, etc.
  - Não trata de *fine-tuning* nem de forma transversal, se limitando a pré-treinamento ou nenhum dos dois.
  - Sem avaliação quantitativa ou métricas de validação.

2.4 Bases de Dados

As buscas foram feitas nos repositórios de artigos *Springer Link* e *ACL Anthology.* A primeira busca foi realizada no *Springer Link*, base que se mostrou promissora em volume de conteúdo para os temas estudados, com recorte temporal de 6 meses. A busca no *ACL Anthology* foi motivada pela busca de uma base mais alinhada com o campo de pesquisa em NLP, e os resultados foram acessados via *Google Scholar.* A terceira busca foi feita no *Springer Link*, sem recorte temporal, utilizando uma *string* de busca mais bem delimitada ao que se deseja pesquisar nesta revisão.

2.5 Strings de Busca

String de busca geral, utilizada no *Springer Link,* com escopo geral:

```
("BERT" OR "encoder-only transformer")
AND
("extractive question answering" OR "question answering" OR
"machine reading comprehension")
AND
("long context" OR "long-context" OR "long document" OR "context window"
OR "sequence length")
AND
(Portuguese OR multilingual OR monolingual OR "language-specific")
```

String utilizada no *Google Scholar* filtrando resultados do *ACL Anthology:*

```
"BERT" question answering "multilingual" "context size"
cross-lingual transfer site:aclanthology.org
```

String utilizada por fim, no *Springer Link:*

```
"cross-lingual transfer" AND "BERT" AND "fine-tuning" AND NOT "LLM"
```

2.6 Perguntas de Avaliação de Qualidade

As Perguntas de Avaliação de Qualidade foram utilizadas para direcionar a leitura dos textos completos a fim de priorizar uma extração de dados efetiva e atenta. As perguntas a serem respondidas durante a leitura do texto completo foram definidas como:

- Como o trabalho apresenta o impacto de contextos longos em inferência?
- Que modelos, técnicas e métricas de avaliação o trabalho traz?
- Como o trabalho apresenta a tarefa de QA Extrativo?
- Como o trabalho discute a questão da inferência translíngue, e que idiomas são trazidos no pré-treinamento e no *fine-tuning?*
- Que limitações, diferenciais e lacunas de pesquisa o trabalho porventura sugere?

2.7 Condução

A condução desta revisão sistemática dá-se a partir da coleta de artigos da base correspondente, realizada a partir de uma *string* de busca formulada a partir das questões de pesquisa e o PICOC. Os artigos duplicados são removidos, e a triagem inicial é realizada, que consiste numa leitura de título e resumo, aplicando os critérios de inclusão e exclusão.

O segundo passo se dá a partir da leitura completa dos artigos retornados, também seguindo os critérios de inclusão e exclusão e registrando-os. No mesmo momento é feito o registro da nota dada ao artigo com base nos critérios de inclusão (ponto positivo) e exclusão (ponto negativo), assim como a anotação de informações que dialogam com tanto com os critérios quanto com as perguntas de pesquisa. Foi definido que, ao final de toda a revisão, seriam considerados aceitos os artigos com nota maior que zero.

Por fim, para a base na qual foi feita a busca, foi feita uma avaliação rápida se o conteúdo apreendido traz progresso evidente na resposta das perguntas de pesquisa. Se não, o processo é repetido reformulando as perguntas de pesquisa e PICOC a fim de construir uma nova *string* de busca, potencialmente em outra base, seguida da pesquisa. Foi dessa forma que esse trabalho se valeu de mais de um método de busca e repositório de artigos, adotando uma postura investigativa e crítica sobre o tema em questão, e sobretudo a metodologia adotada para buscar o conhecimento.

3 Resultados das Triagens

Foram removidos 5 artigos duplicados. As 3 buscas, correspondentes a 2 bases, retornaram no total 394 resultados de pesquisa (soma de 389 artigos encontrados no total e 5 resultados duplicados). Após triagem por título e resumo, sobraram 39 artigos. Após

leitura por texto completo, restaram 16 artigos, que logo em seguida tiveram seus dados extraídos após a análise individual dos critérios de inclusão e exclusão.

Por base, a primeira busca no *Springer Link* retornou 98 trabalhos, sendo 25 passados para leitura completa, e 10 aceitos. A segunda busca, no *ACL Anthology* retornou 46 resultados, tendo 4 sido lidos inteiramente e 2 aceitos. A terceira busca, também no *Springer Link*, trouxe 250 artigos, com 5 duplicados, 10 lidos na totalidade e 4 aceitos. Os resultados da triagem são mostrados a seguir, assim como o fluxograma da busca consolidada entre as bases.

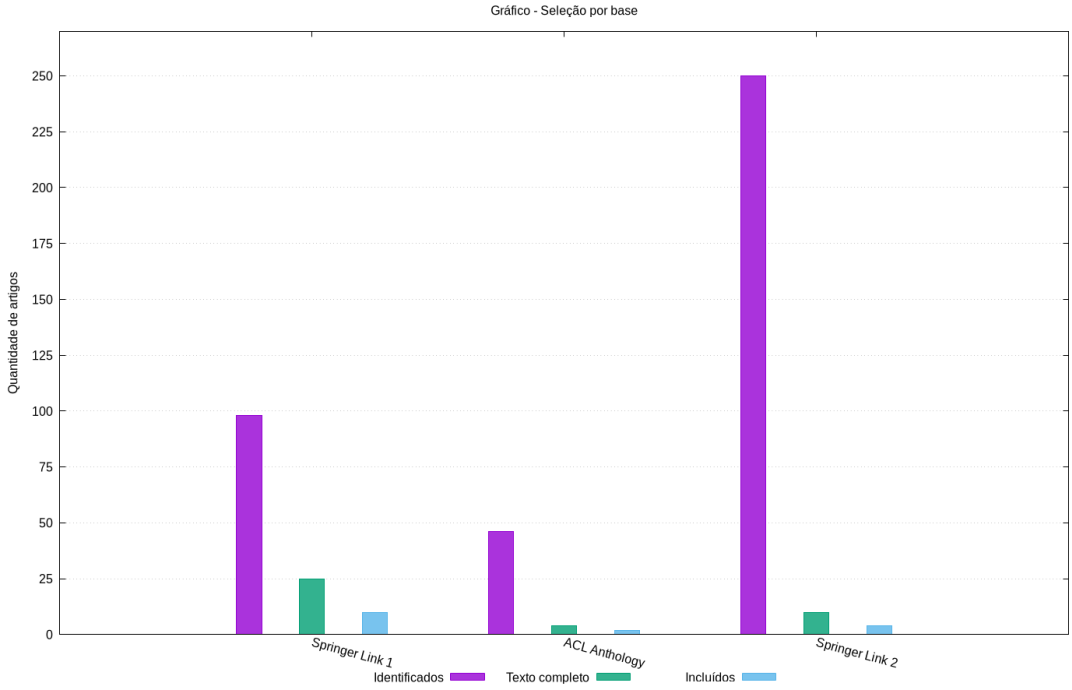


Figura 1: Gráfico de Resultados por Base

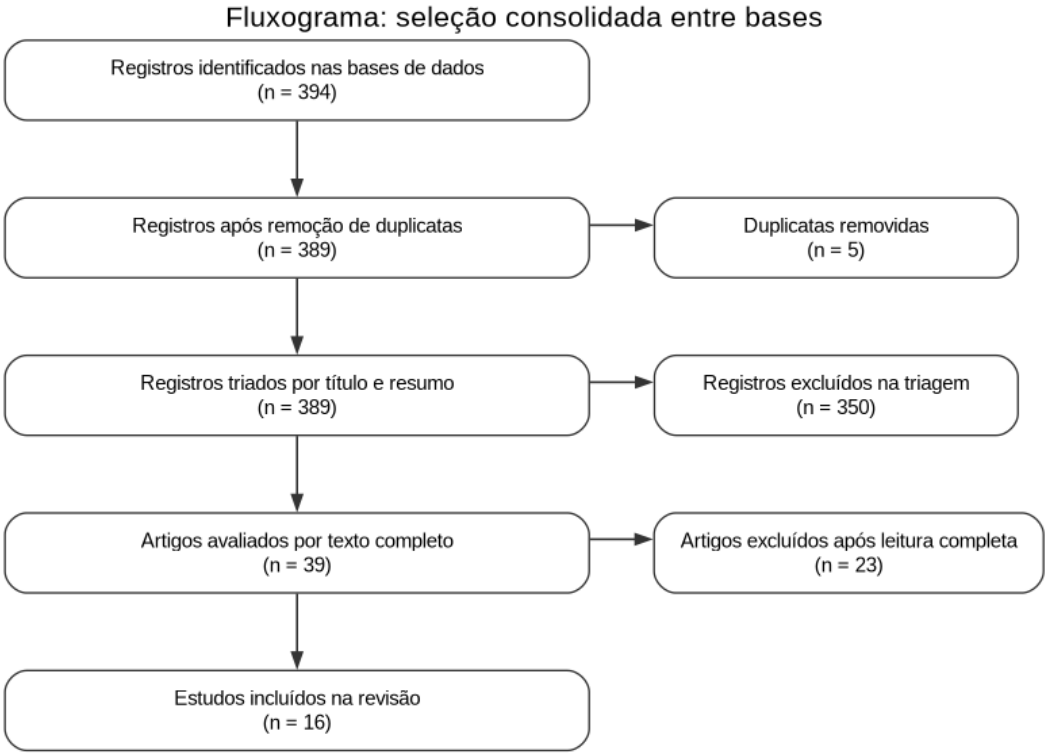


Figura 2: Fluxograma de seleção e triagem consolidada de artigos

Os artigos aceitos, suas respectivas identificações, critérios observados e anotações, podem ser vistos na tabela-resumo em anexo.

3.1 Análise Qualitativa dos Resultados

Após a realização da análise dos artigos, responde-se as questões de pesquisa uma a uma.

3.1.1 Qual o estado da arte no *Question Answering* Extrativo?

O uso de LLMs para tarefas de extração de passagens no texto que respondam perguntas é comum, mas nem sempre é a opção mais performática, econômica e precisa.

Tarefas de classificação, tais como QA Extrativo, podem ser feitas com tais modelos generativos, como LLMs. No entanto, resultados podem ser inferiores: tais modelos perdem atenção de *tokens* mais distantes, podendo causar "esquecimento" das informações ou alucinações. Por outro lado, modelos encoder-only tais como BERT podem retornar resultados de extração melhores, por terem um mecanismo de atenção bidirecional, que evita esse efeito [1, 10]. De forma geral, em comparação com LLMs, modelos BERT têm vantagens de custo, latência e não estarem expostos a alucinações, sendo tão bons ou até melhores para muitas tarefas por conta desse mecanismo de atenção [7].

Especialmente por esses motivo, os modelos *encoder-only* em geral dominam os *benchmarks* de QA Extrativo. SQuAD 2.0 *(Stanford Question Answering Dataset)* é um *dataset* muito utilizado em QA [3, 1], no qual o texto, a passagem da resposta e os índices dos caracteres na passagem da resposta fazem parte do conjunto de dados para treinar o modelo. EM *(Exact Match)* e *token-level F1* são métricas comumente utilizadas para avaliação nessa tarefa específica [6]. Ainda sustentando o uso de modelos *encoder-only,*

trabalhos existentes deixam muito claro que LLMs podem demonstrar imprecisão na detecção dos índices, resultando em desempenho pior que modelos BERT em *benchmarks* [2].

- **Como o alinhamento entre a língua do pré-treinamento e do fine-tuning influencia o desempenho de modelos baseados em BERT em Question Answering extrativo, entre outras tarefas *downstream?***

  – Sei la

Ambala:

Além da importância do alinhamento do idioma de pré-treinamento e *fine-tuning,* idioma do *dataset* também é um fator importante a se considerar, sendo *datasets* nativos mais confiáveis do que traduções automáticas de *datasets* em inglês. A menor representação de certos idiomas no pré-treinamento pode afetar a qualidade da inferência.

Oliveira:

Define como "Maldição da Multilingualidade" o fenômeno em que o desempenho de um modelo de IA diminui à medida que é treinado para cobrir mais línguas simultaneamente, notadamente em idiomas menos representados.

Savant:

Idiomas menos representados no pré-treinamento de modelos multilíngues são prejudicados. SQuAD é um excelente dataset cujo uso acelera o desenvolvimento em contraste com datasets nativos bem menores, mas tradução automática pode comprometê-lo, em especial para a tarefa de QA, no qual o alinhamento de *spans* pode ser comprometido.

Sharma:

Mostra modelo BERT desempenhando QA bem sem precisar necessariamente de *fine-tuning* naquele contexto específico, mostrando o potencial de inferência *zero-shot* do modelo para essa tarefa.

Ramy:

Sustenta de forma ainda mais contundente o efeito da "Maldição da Multilingualidade", trazendo uma avaliação de desempenho de modelos para a tarefa de NER. Compara modelos pré-treinados em idioma nativo, em famílias de idiomas e em diversos idiomas não relacionados (prática comum utilizada nos modelos BERT multilíngues mais conhecidos, como mBERT e XML-R). O efeito observado é que cada categoria respectivamente mencionada supera a outra em desempenho.

Villegas:

Traz limitações a respeito de modelos multilígues terem limitações, notadamente no que diz respeito ao desempenho em linguagem informal ou regional, o que benchmarks comuns não mostram, notadamente no idioma português.

Kyaw:

Reconhece que modelos multilíngues são capazes de capturar relações linguísticas entre os idiomas. O estudo compara modelo nativo, multilíngue, e uma arquitetura distinta. Conclui que pré-treinamento em idioma nativo é crucial para bons resultados.

Edeti:

Generalização translíngue abarca inclusive idiomas *low-resource,* como Oromo.

Deshpande:

Sugere que modelos maiores mostram desempenho de QA Extrativo melhor.

Yadav:

É feita uma estratégia de validação na qual o modelo é treinado em vários idiomas, mas testado em um idioma deixado de fora (incluindo o português). Isso gerou métricas de queda de desempenho na transferência translígue, apesar de pequenas.

- **Como a literatura caracteriza o desempenho qualitativo de modelos encoder-only monolíngues e multilíngues em tarefas de Question Answering extrativo em português, dentre outras tarefas *downstream*?**

  – Nao sei

Oliveira:

Os resultados são convincentes, a partir do fato que a avaliação é feita utilizando *dataset* totalmente nativo, o LeNER-Br [4], especializado em informação jurídica. Explicitamente mostra a superioridade de modelos monolíngues em português em comparação com modelos multilíngues em métricas de precisão, acurácia e *F1-score*.

Enzo:

Levanta que é sabido que modelos nativos em português já existentes há um tempo, como o BERTtimbau, já superaram multilíngues em diversas tarefas de inferência no idioma português. O modelo nativo apresentado no trabalho, o NorBERTo, performa bem, mesmo não sendo pré-treinado em tanto conteúdo quando o ModernBERT original, informação que sustenta ainda mais a superioridade dos modelos nativos mesmo quando com menor contagem de parâmetros.

- **Qual é a influência do tamanho do texto a ser processado no desempenho qualitativo de modelos baseados em BERT para tarefas downstream, em particular o QA Extrativo?**

  – Nao sei

Oliveira:

Conclui considerando possíveis trabalhos futuros como aqueles que tratem de longo contexto ou utilizem melhor as capacidades de longo contexto do ModernBERT (8192 *tokens*), visto que o BERTomelo possui suporte apenas a 1024.

Le:

Sugere que "muitos detalhes"no texto pode prejudicar o desempenho do modelo em QA extrativo, o que indica potencial lacuna dos modelos BERT em QA de longo contexto.

Tiwari:

Modelo BERT possui o poder da atenção bidirecional que já ajuda na compreensão de longos contextos.

Deshpande:

O artigo menciona trabalhos nos quais é evidenciado que a atenção dos modelos BERT fica naturalmente distribuída entre palavras semanticamente importantes independentes da sua posição, enquando modelos generativos têm atenção decaída em tokens mais distantes. [1]

4 Conclusões

Suas conclusões.

Referências

[1] Sudhindra Deshpande, Priyanka Desai, Kah Ong Michael Goh, Pratijnya Ajawan, Kadayya Mathad, and Uttam Deshpande. A comprehensive comparative analysis of transformer based large language models across natural language processing benchmarks. *Discover Artificial Intelligence*, 6, 07 2026.

[2] Luís B. Elvas and Carolina Carvalho. Domain-specific versus general large language models: a review and empirical benchmark in real medical texts. *Scientific Reports*, 16(1):24933, 2026.

[3] Nguyen Khang, Hien Nguyen, Thi-Thu-Trang Nguyen, Phuong Nguyen, Tung Le, and Le Nguyen. *A Novel Pipeline to Enhance Question-Answering Model by Identifying Relevant Information*, pages 296–311. 07 2023.

[4] Pedro Henrique Luz de Araujo, Teófilo E. de Campos, Renato R. R. de Oliveira, Matheus Stauffer, Samuel Couto, and Paulo Bermejo. Lener-br: A dataset for named entity recognition in brazilian legal text. In *Computational Processing of the Portuguese Language: 13th International Conference, PROPOR 2018, Canela, Brazil, September 2426, 2018, Proceedings*, page 313323, Berlin, Heidelberg, 2018. Springer-Verlag.

[5] MA Ning and Wu Di. Research on machine reading comprehension integrating long-distance entity relations and entity-level linguistic cues. *Human-Centric Intelligent Systems*, 04 2026.

[6] Siddesh Savant, Uttam Deshpande, and Jovi DSilva. Systematic review and comparative synthesis of cross lingual question answering systems for low resource indic languages. *Discover Artificial Intelligence*, 6, 09 2026.

[7] Enzo S. N. Silva, Pablo B. Costa, Raphael C. Vlasman, Rosimeire P. Costa, Henrique L. P. Silva, Lucas F. A. O. Pellicer, Guilherme Rinaldo, Renato A. Almeida, Darian S. R. Rabbani, Cinthya O. Oestreich, and Vinicius F. Caridá. NorBERTo: A ModernBERT model trained for Portuguese with 331 billion tokens corpus. In Marlo Souza, Iria de Dios-Flores, Diana Santos, Larissa Freitas, Jackson Wilke da Cruz Souza, and Eugénio Ribeiro, editors, *Proceedings of the 17th International Conference on Computational Processing of Portuguese (PROPOR 2026) - Vol. 1*, pages 183–193, Salvador, Brazil, April 2026. Association for Computational Linguistics.

[8] Fahim Sufi and Ibrahim Khalil. Automated disaster monitoring from social media posts using ai-based location intelligence and sentiment analysis. *IEEE Transactions on Computational Social Systems*, 11:4614–4624, 01 2022.

[9] William Villegas, Rommel Gutierrez, Aracely Mera-Navarrete, and Rodrigo Guevara-Reyes. Multilingual evaluation of semantic robustness and cultural adaptability in transformer models for emotion recognition. *Cognitive Computation*, 18, 06 2026.

[10] Yuan Wei, Noor Hamzani Farizan, and Cheng Ji. A psychological education model integrating artificial intelligence-based bert in physical education. *Scientific Reports*, 16, 05 2026.

5 Planilha-resumo dos Resultados

Tabela 1: Planilha-resumo dos trabalhos selecionados

Trabalho	I1	I2	I3	I4	I5	E1	E2	E3	E4	Observações
Ambala, S., Selvi, M., Kiruba, S. et al. NTAM: Neural Transfer Alignment for Cross-Lingual Question Answering in Low-Resource Indian Languages. SN COMPUT. SCI. 7, 526 (2026). https://doi.org/10.1007/s42979-026-05111-4	X	X	X		X					Discute a importância de *datasets* nativos em vez de traduções automáticas; aponta que a menor representação de certos idiomas no treinamento pode afetar a qualidade da inferência; considera o alinhamento uma precondição para a transferência bem-sucedida.
Oliveira, Rennê & Erven, Gustavo & Garcia, Luís. (2026). BERTomelo: Your Portuguese Encoder Best Friend. 10.48550/arXiv.2606.28999.	X	X	X	X						Apresenta a "maldição da multilingualidade", afirmando a superioridade de modelos monolíngues para tarefas em idoma nativo em comparação com multilíngues, com exemplos, e contextualiza na língua portuguesa. Com modelo baseado em *ModernBERT* com 1024 *tokens*, o BERTomelo, apresenta que longo contexto é um objeto de estudo a ser pesquisado em trabalhos futuros.
Savant, S., Deshpande, U.U. & D'Silva, J. Systematic review and comparative synthesis of cross lingual question answering systems for low resource Indic languages. Discov Artif Intell 6, 1065 (2026). https://doi.org/10.1007/s44163-026-01750-x	X	X			X					QA Extrativo é um tipo especial de QA dentre muitos, no qual o BERT se destaca, e o mais sensível a problemas de tradução. Métricas principais: EM e *token-level* F1. Idiomas menos representados no treinamento de modelos multilíngues são prejudicados. SQuAD é um excelente dataset que acelera o desenvolvimento em contraste com *datasets* nativos bem menores, mas tradução automática pode comprometê-lo. O principal problema é o alinhamento de *spans*.
Sharma, V.K., Sethi, K.H., Saran, S. et al. Automated Natural Disaster Monitoring from Online News & Social Media Posts Using Sentiment Analysis & GIS. Earth Syst Environ 10, 13301–13339 (2026). https://doi.org/10.1007/s41748-026-01305-1	X		X		X					Mostra o QA Extrativo em uma aplicação específica: inferir locais de desastres naturais. Apresenta modelo de classificação desempenhando QA bem sem precisar de *fine-tuning* naquele contexto específico.
Enzo S. N. Silva, Pablo B. Costa, Raphael C. Vlasman, Rosimeire P. Costa, Henrique L. P. Silva, Lucas F. A. O. Pellicer, Guilherme Rinaldo, Renato A. Almeida, Darian S. R. Rabbani, Cinthya O. Oestreich, and Vinicius F. Caridá. 2026. NorBERTo: A ModernBERT Model Trained for Portuguese with 331 Billion Tokens Corpus. In Proceedings of the 17th International Conference on Computational Processing of Portuguese (PROPOR 2026) - Vol. 1, pages 183–193, Salvador, Brazil. Association for Computational Linguistics.	X		X	X						Em comparação com LLMs, modelos BERT têm vantagens de custo, latência e não estarem expostos a alucinações, sendo tão bons ou até melhores para muitas tarefas. Sugere que modelos nativos, como BERTimbau em português, superaram multilíngues em diversas tarefas. Apresenta um modelo baseado em ModernBERT, o NorBERTo, que performa bem, mesmo não sendo pré-treinado em tanto conteúdo quando o ModernBERT original.

Continua na próxima página

Tabela 1 – continuação

Trabalho	I1	I2	I3	I4	I5	E1	E2	E3	E4	Observações
Ramy Eskander, Shubhanshu Mishra, Sneha Mehta, Sofia Samaniego, and Aria Haghighi. 2022. Towards Improved Distantly Supervised Multilingual Named-Entity Recognition for Tweets. In Proceedings of the 2nd Workshop on Multi-lingual Representation Learning (MRL), pages 115–124, Abu Dhabi, United Arab Emirates (Hybrid). Association for Computational Linguistics.	X	X	X							Mostra de forma detalhada um *benchmark* de *fine-tuning* de modelos de classificação para NER *(Named Entity Recognition).* Compara modelos nativos, multilíngues em famílias de idiomas, e multilíngues em idiomas de origens diversas, uma categoria se sobressaindo à outra, respectivamente.
Villegas-Ch, W., Gutierrez, R., Mera-Navarrete, A. et al. Multilingual Evaluation of Semantic Robustness and Cultural Adaptability in Transformer Models for Emotion Recognition. Cogn Comput 18, 73 (2026). https://doi.org/10.1007/s12559-026-10621-7	X	X	X							Desambigua termos: idioma *low-resource* e *less-represented.* Traz limitações a respeito de modelos multilígues terem limitações, notadamente no que diz respeito ao desempenho em linguagem informal ou regional, o que *benchmarks* comuns não mostram, notadamente no idioma português.
., C., Kyaw, K.T., Jain, R. et al. A systematic evaluation of transformer-based architectures for fake news detection in the low-resource Burmese language. Sci Rep 16, 25667 (2026). https://doi.org/10.1038/s41598-026-56647-7	X	X	X							Reconhece que modelos multilíngues são capazes de capturar relações linguísticas entre os idiomas. O esetudo compara modelo nativo, multilíngue, e uma arquitetura distinta. Conclui que pré-treinamento em idioma nativo é crucial para bons resultados.
Le, NK., Nguyen, DH., Nguyen, TTT., Nguyen, M.P., Le, T., Nguyen, M.L. (2023). A Novel Pipeline to Enhance Question-Answering Model by Identifying Relevant Information. In: Yada, K., Takama, Y., Mineshima, K., Satoh, K. (eds) New Frontiers in Artificial Intelligence. JSAI-isAI 2021. Lecture Notes in Computer Science(), vol 13856. Springer, Cham. https://doi.org/10.1007/978-3-031-36190-6_21	X		X		X					Desambigua sistema de QA tradicional e moderno (similares a RAG). Introduz SQuAD 2.0, e traz como métricas de avaliação EM e *F1-score.* Sugere que "muitos detalhes"no texto pode prejudicar o desempenho do modelo em QA extrativo.
Wei, Y., Farizan, N.H. & Ji, C. A psychological education model integrating artificial intelligence-based BERT in physical education. Sci Rep 16, 24556 (2026). https://doi.org/10.1038/s41598-026-55734-z	X		X							Explica a superioridade do processamento bidirecional de modelos BERT frente a outras alternativas, e como *Transformers* revolucionaram o meio de NLP com *self-attention.*
Edeti, L., Meshesha, M. & Negesse, F. Small language models efficacy prototyped for Oromo word sense disambiguation. Discov Computing 29, 322 (2026). https://doi.org/10.1007/s10791-026-10155-4	X		X							Utilizando modelos de estado da arte, o trabalho apresenta um *pipeline* de análise de sentimento que performa bem mesmo em contextos multilíngues.
Tiwari, R.G., Shukla, V.K., Dutt, K. et al. Leveraging bidirectional encoder representations from transformers (BERT) for enhanced fake news detection on social media. SN Soc Sci 6, 154 (2026). https://doi.org/10.1007/s43545-026-01425-5	X		X							O trabalho apresenta o poder da atenção bidirecional dos modelos BERT para compreensão textual em longos contextos.
Ning, M., Di, W. Research on Machine Reading Comprehension Integrating Long-Distance Entity Relations and Entity-Level Linguistic Cues. Hum-Cent Intell Syst (2026). https://doi.org/10.1007/s44230-026-00154-5	X			X				X		Traz a ideia de *Machine Reading Comprehension* como área de estudo. Utiliza heurísticas para busca de informações em grandes contextos.

Continua na próxima página

Tabela 1 – continuação

Trabalho	I1	I2	I3	I4	I5	E1	E2	E3	E4	Observações
Deshpande, S.B., Desai, P., Goh, . et al. A comprehensive comparative analysis of transformer based large language models across natural language processing benchmarks. Discov Artif Intell 6, 1326 (2026). https://doi.org/10.1007/s44163-026-01700-7	X				X		X			Sustenta que tarefas de classificação podem ser feitas com modelos generativos, mas modelos *enconder-only* tais como BERT podem ser melhores, por ter pré-treinamento bidirecional. Utiliza SQuAD v2 como *dataset* experimental de QA. Traz métricas de EM e *F1-score.* Sugere que modelos maiores mostram desempenho de QA Extrativo melhor. Sobre longo contexto, o artigo menciona trabalhos nos quais é evidenciado que a atenção dos modelos BERT fica naturalmente distribuída entre palavras semanticamente importantes independentes da sua posição, enquando modelos generativos têm atenção decaída em *tokens* mais distantes.
Yadav, R., Yadav, D.K., Jain, A. et al. Cross-lingual sentiment analysis via multimodal transformer fusion and lightweight deep ensemble learning framework. Knowl Inf Syst 68, 151 (2026). https://doi.org/10.1007/s10115-026-02768-4	X		X			X				É feita uma estratégia de validação na qual o modelo é treinado em vários idiomas, mas testado em um idioma deixado de fora (incluindo o português). Isso gerou métricas de queda de desempenho na transferência translígue, apesar de pequenas.
Elvas, L.B., Carvalho, C. Domain-specific versus general large language models: a review and empirical benchmark in real medical texts. Sci Rep 16, 24933 (2026). https://doi.org/10.1038/s41598-026-62884-7	X		X					X		A escassez de dados em idioma nativo para *fine-tuning* é um grande problema no treinamento de modelos BERT. LLMs não demonstraram precisão de inferência de *spans,* ao contrário de modelos BERT em diversas tarefas *downstream.*