REVISÃO SISTEMÁTICA DA LITERATURA (RSL)

# Capacidade de Transferência Translíngue e Longo Contexto em Modelos BERT para QA Extrativo

**Victor Hugo Santos Bitencourt**

Departamento de Ciências Exatas e da Terra — Campus I

Universidade do Estado da Bahia (UNEB) • Salvador, Brasil

CONTEXTUALIZAÇÃO

# Modelos Encoder-Only vs. LLMs Generativos

### Modelos BERT (Encoder-Only)

Atenção bidirecional nativa sem perda de foco em tokens distantes. Alta precisão na delimitação de índices de respostas, menor latência e custo computacional reduzido sem risco de alucinações.

### LLMs Generativos

Decaimento de atenção em trechos distantes durante a geração. Dificuldade empírica na identificação exata de spans de texto em tarefas formais de Question Answering Extrativo.

ESTRUTURAÇÃO DA PESQUISA

# Mapeamento Metodológico via Framework PICOC

**P**

**População**

Modelos Transformers Encoder-Only (família BERT) aplicados a QA Extrativo.

**I**

**Intervenção**

Janelas de contexto ampliadas e modelos monolíngues especializados por idioma.

**C**

**Comparação**

Modelos multilíngues genéricos e arquiteturas com janelas padrão restritas.

**O**

**Resultado**

Métricas de desempenho (EM e F1) sob variação de tamanho de contexto.

**C**

**Contexto**

Processamento de documentos longos e transferência para o português.

METODOLOGIA DE SELEÇÃO

# Funil de Seleção e Mapeamento dos Artigos (PRISMA)

**389**

**Estudos Encontrados**

Busca inicial em bases (Springer Link e ACL/Scholar)

**39**

**Triagem de Título/Resumo**

Aplicação direta dos critérios I/E

**16**

**Artigos Aprovados**

Leitura completa e extração de dados final

QUESTÃO DE PESQUISA 01

# Estado da Arte em Question Answering Extrativo

### Atenção Bidirecional Superior

Modelos encoder-only dominam benchmarks de QA extrativo por preservarem contexto completo sem perda de atenção em trechos distantes.

### Métricas Padronizadas

A avaliação consolida-se através de Exact Match (EM) e token-level F1-score sobre datasets de referência como o SQuAD 2.0.

### Capacidade Zero-Shot

Capacidade comprovada de inferência precisa em domínios específicos sem necessidade de fine-tuning prévio constante.

> "Modelos generativos apresentam imprecisão na identificação de índices exatos, tornando os encoders a escolha ideal para extração rígida de passagens."
>
> — Evidência Sintetizada da RSL

QUESTÃO DE PESQUISA 02

# A ”Maldição da Multilingualidade”

### Modelos Multilíngues (mBERT / XLM-R)

Permitem transferência para idiomas com baixos recursos computacionais ao capturar relações estruturais genéricas.

Gargalo: Degradação de desempenho à medida que a quantidade de línguas cobertas aumenta.

### Modelos Monolíngues Nativos

Especialização profunda no léxico e gramática local, superando modelos multilíngues de maior porte.

Vantagem: Maior alinhamento em nuances culturais, termos regionais e linguagem informal.

QUESTÃO DE PESQUISA 03

# Modelos Encoder-Only para a Língua Portuguesa

### BERTimbau

Consolidou a superioridade monolíngue sobre modelos multilíngues em tarefas clássicas de inferência no português.

### BERTomelo

Especializado com datasets jurídicos nativos (LeNER-Br), superando baselines em acurácia e F1-score.

### NorBERTo

Baseado em ModernBERT e treinado em 331B tokens; destaca-se pela alta eficiência mesmo com menor contagem de parâmetros.

QUESTÃO DE PESQUISA 04

# O Desafio do Processamento de Longos Contextos

### Potencial Teórico

Mecanismos de self-attention bidirecional distribuem a relevância semântica uniformemente ao longo do texto.

### Limitação Empírica

Excesso de detalhes ruidosos ("muitos detalhes") pode prejudicar a precisão da extração em documentos extensos.

OPORTUNIDADE DE PESQUISA

# A lacuna de expansão com a arquitetura ModernBERT

1024

Janela típica em modelos locais atuais

→

8192

**Tokens de capacidade no ModernBERT**

SÍNTESE DOS ACHADOS

# Conclusões da RSL

- Transferência translíngue funciona, mas perde desempenho qualitativo frente a modelos nativos.
- Datasets nativos garantem maior confiabilidade técnica em relação a traduções automáticas.
- O impacto de contextos longos em QA extrativo permanece uma lacuna metodológica em aberto.

DIRECIONAMENTOS

# Agenda de Trabalhos Futuros

### Avaliação de Janelas Expandidas

Investigar empiricamente o comportamento do QA extrativo sob janelas de 8192 tokens no ModernBERT.

### Datasets Nativos em Português

Fomentar a criação de conjuntos de dados de QA de longo contexto não traduzidos para o idioma luso-brasileiro.

OBRIGADO

# Perguntas e Discussão

Revisão Sistemática sobre Capacidade de Transferência Translíngue em Inferência de Modelos BERT

abjurandam@gmail.com